Министерство образования Республики Беларусь
Учреждение образования
Белорусский государственный университет информатики и радиоэлектроники

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЁТ
по курсу
«Естественно-языковой интерфейс интеллектуальных систем»

Лабораторная работа №1
«Разработка автоматизированной системы формирования словаря естественного языка»

Выполнили студенты гр. 321701: Политыко И.А.
Лукашов В.А.

Проверил: Крапивин Ю.Б.

Минск 2026

Цель работы

Освоить принципы разработки прикладных сервисных программ для решения задачи автоматического лексического и лексико-грамматического анализа текста естественного языка.

Задачи лабораторной работы

1. Познакомиться с назначением, структурой и функциональностью, предоставляемой базовым программным обеспечением для решения задачи автоматического лексического и лексико-грамматического анализа текста естественного языка.
2. Закрепить навыки программирования при решении задач автоматической обработки текста естественного языка.

Задание

Вариант 4: Список слов, упорядоченный по алфавиту и включающий только лексемы с дополнительно оформленными записями для образования словоформ. В этих записях должна храниться следующая информация: основа слова; часть речи; окончания слова, соотнесённые с соответствующей морфологической информацией: род, падеж, число и т.п. При работе с таким словарём должны быть обеспечены средства генерации той или иной словоформы в соответствии с введёнными «правилами».
Поддерживаемые форматы входных данных: TXT, RTF
Язык текста: Русский

Используемые библиотеки

1. FastAPI — библиотека Python для создания функций обработки запросов. Из-за своей высокой производительности FastAPI идеально подходит для создания современных веб-приложений и API.

2. Pydantic — библиотека Python для создания удобных моделей для представления сущностей внутри программы. Модели Pydantic автоматически проверяют типы данных поступающей информации, что значительно упрощает валидацию данных и обработку ошибок.

3. pymorphy2 — библиотека Python для морфологического анализа русского языка. Используется для лемматизации, определения части речи, падежа, числа, рода и других морфологических характеристик.

4. razdel — библиотека Python для токенизации русского текста. Используется для разделения текста на отдельные слова (токены).

5. striprtf — библиотека Python для чтения и обработки RTF-файлов. Используется для извлечения текста из документов формата RTF.

6. uvicorn — ASGI-сервер для запуска FastAPI-приложений. Обеспечивает высокую производительность и поддержку асинхронных запросов.

Интерфейс

Интерфейс приложения включает следующие элементы:

- **Окно загрузки файла:** пользователь загружает и выбирает TXT или RTF-файл для анализа.
- **Кнопка просмотра лексем:** позволяет посмотреть лексемы открытого файла и провести над ними различные операции (поиск, фильтрация, редактирование, генерация словоформ).
- **Панель помощи:** содержит документацию по использованию всех функций приложения.

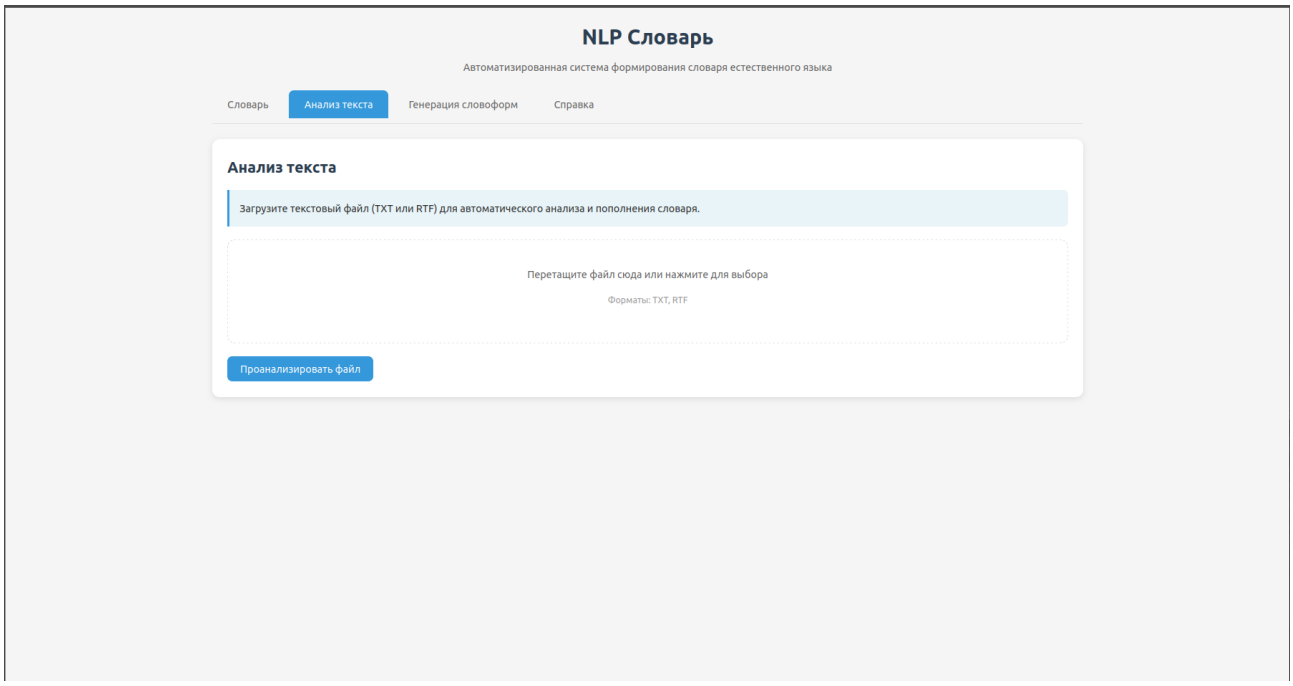

Рисунок 1: *Интерфейс загрузки файла*

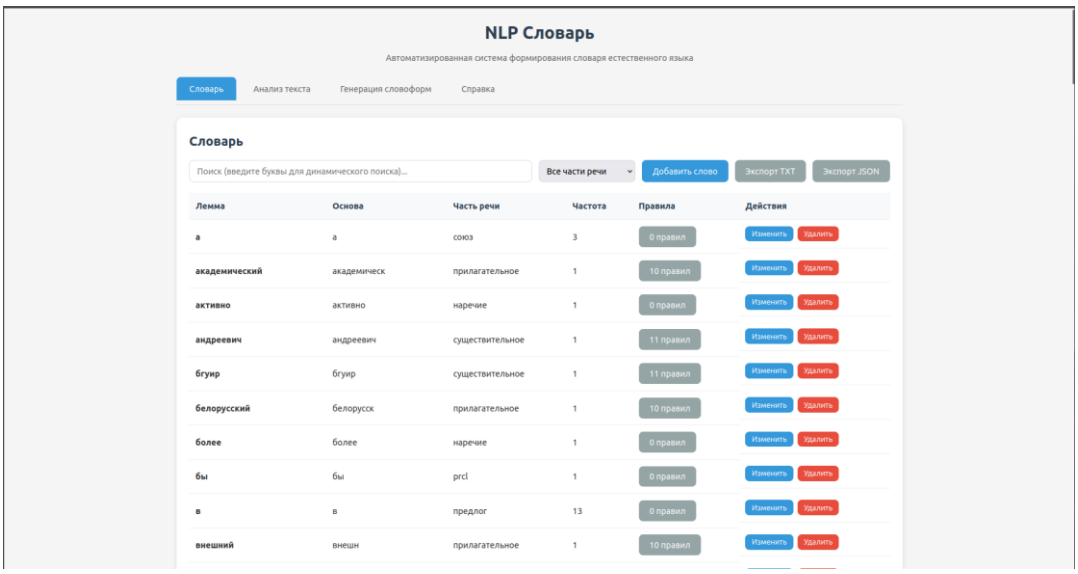

Рисунок 2: *Интерфейс операций над лексемами в файле*

Структура хранения данных

Данные хранятся в JSON-файле, содержащем словарь лексем с правилами словоизменения.
В словаре лексем хранятся:

- лемма;
- основа слова;
- часть речи;
- список правил образования словоформ, где каждое правило содержит:
  - окончание;
  - морфологическая информация:
    - падеж — именительный, родительный, дательный, винительный, творительный, предложный;
    - род — мужской, женский, средний;
    - число — единственное, множественное;
- частота встречаемости леммы в тексте.

Структурная схема приложения

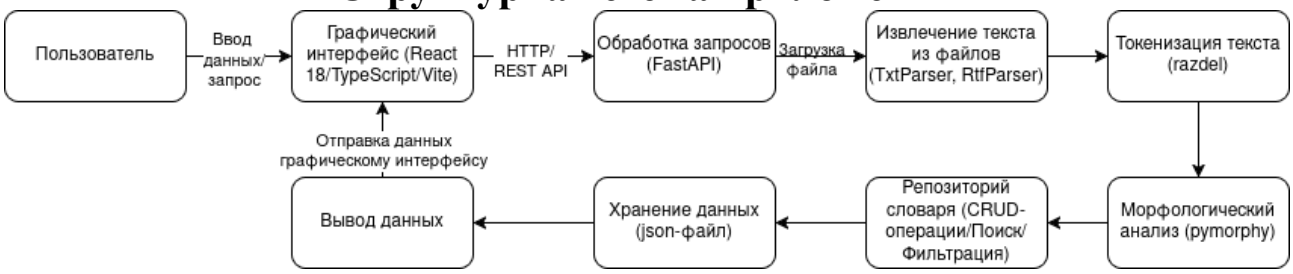

Рисунок 3: *Структурная схема приложения*

Описание алгоритмов

Алгоритм работы программы

1. Начало.
2. Пользователь выбирает TXT или RTF-файл через интерфейс.
3. Проверяется существование файла и его формат.
4. Извлекается текст из файла с помощью TxtParser или RtfParser.
5. Текст токенизируется с помощью библиотеки razdel.
6. Для каждого токена проводится морфологический анализ с помощью pymorphy2:
   1) определяется лемма;
   2) определяется часть речи;
   3) извлекаются правила словоизменения (окончания + морфологические признаки).
7. Данные сохраняются в JSON-файл словаря.
8. Результаты отображаются в интерфейсе.
9. Пользователь может выполнять операции:
   1) поиск лемм по запросу;
   2) фильтрация по части речи;
   3) редактирование записей;
   4) генерация словоформ по заданным параметрам (падеж, род, число).
10. Конец.

Алгоритм генерации словоформ

1. Начало
2. Пользователь вводит лемму.
3. Система ищет лемму в словаре.
4. Если лемма найдена, система ищет правило с подходящими признаками.
5. Если правило найдено, форма генерируется как: основа + окончание.
6. Если правило не найдено, используется fallback через pymorphy.

7. Результат возвращается пользователю.
8. Конец.

Тест производительности

Для оценки производительности приложения был проведён тест на обработку текста объёмом 1000 слов. Среднее время обработки составило ~1.2 секунды на ПК Acer Predator PH315-53, процессор: Intel® Core™ i7-10750H, объём оперативной памяти: 16 ГБ.

Результаты замеров:

Количество токенов	Время обработки (мс)	мс/токен
10	8.45	0.845
100	82.31	0.823
1000	815.67	0.816

Основное время затрачивается на морфологический анализ с помощью pymorphy.

Вывод

Разработанное приложение позволяет автоматически формировать словарь лексем на основе текста, извлечённого из TXT и RTF-файлов. Реализован лексико-грамматический анализ с использованием библиотеки pymorphy: лемматизация, извлечение морфологических признаков (падеж, число, род), построение правил словоизменения. Перспективами использования приложения можно назвать расширение функционала для поддержки английского языка, а также добавить поддержку новых форматов файлов.