Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

К защите допустить:

Заведующий кафедрой ИИТ

_____ Д. В. Шункевич

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовому проекту
по дисциплине «Проектирование баз знаний»
на тему:

Интеллектуальный медицинский ассистент

БГУИР КП5 6-05-0611-03-056 ПЗ

Студент гр. 321701 И. А. Политыко
Руководитель Д. А. Сальников

Минск 2025

СОДЕРЖАНИЕ

Перечень условных обозначений 6
Введение 8
1 Анализ 10
1.1 Анализ предметной области 10
1.2 Постановка задачи 10
1.3 Требования к решению 11
1.4 Анализ аналогов 13
1.5 Анализ подходов к решению проблемы 17
1.6 Вывод 18
2 Проектирование 19
2.1 Анализ пользователей 31
2.2 Вывод 31
3 Разработка 33
3.1 Используемые технологии 33
3.2 Демонстрация пользовательского интерфейса 33
3.3 Тестирование 42
3.4 Вывод 43
Список использованных источников 44

ПЕРЕЧЕНЬ УСЛОВНЫХ ОБОЗНАЧЕНИЙ

БД — База данных;
БЗ — База знаний;
ГБ — Гигабайт;
ИИ — Искусственный интеллект;
ИТ — Информационные технологии;
КТ — Компьютерная томография;
Минздрав России — Министерство здравоохранения России;
МО — Машинное обучение;
НГУ — Новосибирский государственный интеллект;
ПГУ — Пензенский государственный университет;
ПО — Программное обеспечение;
СППВР — Системы поддержки принятия врачебных решений;
СУБД — Система управления базами данных;
ЭМК — Электронная медицинская карта;
AI (от англ. Artificial Intelligence) — Искусственный интеллект;
Aidoc (от англ. Artificial Intelligence Doctor) — Искусственный интеллект для врачей;
API (от англ. Application Programming Interface) — Программный интерфейс приложения;
AWS (от англ. Amazon Web Services) — Облачная платформа "Веб-сервисы от Amazon";
CDA (от англ. Clinical Document Architecture) — Клиническая архитектура документов;
ChatGPT (от англ. Generative Pre-trained Transformer) — Генерирующий предобученный трансформер для чата;
CRF (от англ. Conditional Random Fields) — Условные случайные поля;
CSS (от англ. Cascading Style Sheets) — Каскадные таблицы стилей;
DICOM (от англ. Digital Imaging and Communications in Medicine) — Цифровое изображение и связь в медицине;
DIMA (MD AI) (от англ. Medical Doctor Artificial Intellignce) — Доказательная медицина и Искусственный интеллект;
EDA (от англ. Event-driven Architecture) — Событийно-ориентированная архитектура;
EHR (от англ. Electronic Health Record) — Электронная медицинская запись;
FHIR (от англ. Fast Healthcare Interoperability Resources) — Ресурсы быстрого взаимодействия в сфере здравоохранения;
GDPR (от англ. General Data Protection Regulation) — Общий регламент по защите данных;

GPU (от англ. Graphics Processing Unit) — Графический процессор;

gRPC (от англ. Google Remote Procedure Call) — Удалённый вызов процедур от Google;

HL7 (от англ. Health Level Seven) — Стандарт обмена, управления и интеграции электронной медицинской информации «Седьмой уровень»;

HTML (от англ. HyperText Markup Language) — Язык гипертекстовой разметки;

IoT (от англ. Internet of Things) — Интернет вещей;

IT (от англ. Information Technologies) — Информационные технологии;

LLM (от англ. Large Language Model) — Большая языковая модель;

MedPlan (от англ. Medical Plan) — Медицинский план;

ML (от англ. Machine Learning) — Машинное обучение;

MQTT (от англ. Message Queuing Telemetry Transport) — Транспорт телеметрии с очередью сообщений;

NLP (от англ. Natural Language Processing) — Обработка естественного языка;

OAuth (от англ. Open Authorization) — Открытая авторизация;

OpenCV (от англ. Open Source Computer Vision Library) — Библиотека алгоритмов компьютерного зрения, обработки изображений и численных алгоритмов общего назначения с открытым кодом;

PACS (от англ. Picture Archiving and Communication System) — Система архивирования и передачи изображений;

PathAI (от англ. Pathology + Artificial Intelligence) — Патология + Искусственный интеллект;

PMC (от англ. Public Medical Center) — Публичный медицинский центр;

RAG (от англ. Retrieval-Augmented Generation) — Генерация, дополненная поиском;

RAGPR (от англ. Retrieval-Augmented Generation-Based Physician Recommendation) — Рекомендация врачей на основе генерации с подкреплением поиском;

REST API (от англ. Representational State Transfer Application Programming Interface) — Передача репрезентативного состояния программного интерфейса приложения;

ROI (от англ. Return On Investment) — Возврат инвестиций;

SVM (от англ. Support Vector Machine) — Машина опорных векторов;

SQL (от англ. Structured Query Language) — Язык структурированных запросов;

TLS (от англ. Transport Layer Security) — Защита транспортного уровня;

WCAG (от англ. Web Content Accessibility Guidelines) — Руководство по доступности веб-контента;

ВВЕДЕНИЕ

Здравоохранение – это динамичная и многоуровневая система, включающая множество взаимосвязанных процессов, среди которых особое место занимает управление медицинскими данными и предоставление персонализированных рекомендаций медицинскому персоналу. Эффективная организация этих процессов, контроль фармакологических назначений, оптимизация взаимодействия с медицинскими учреждениями и своевременное выявление рисков требуют применения современных цифровых решений, основанных на обработке данных, нормативных требованиях и передовых технологиях.

В эпоху цифровизации ключевое значение приобретает создание и внедрение интеллектуальных систем поддержки медицинского персонала. Использование технологий *искусственного интеллекта* (*ИИ*) позволяет автоматизировать анализ данных, повышая их надёжность и экономическую эффективность. Такие системы, оснащённые централизованными *базами знаний* (*БЗ*), способны агрегировать и анализировать информацию в реальном времени, что ускоряет принятие клинических решений и улучшает работу всей инфраструктуры.

Для успешной реализации подобных систем необходимо разработать структурированную *БЗ*, включающую: данные о фармакологических препаратах и их взаимодействиях; характеристики медицинских изображений для анализа; информацию о возможных заболеваниях и методах их распознавания; сведения о взаимодействии с медицинскими учреждениями и их эксплуатационных особенностях. (Примечание: сбор и агрегация данных представляет собой сложную задачу, поскольку специализированные медицинские *базы данных* (*БД*) часто являются дорогими и труднодоступными. В проекте планируется использовать открытые источники и агрегированные датасеты для прототипа.).

Такой подход позволяет не только повысить эффективность работы системы здравоохранения, но и минимизировать риски диагностических ошибок благодаря предиктивной аналитике. Формирование *БЗ* позволит систематизировать данные о ключевых аспектах здоровья: фармакологических рекомендациях, характеристиках медицинских изображений, стратегиях предотвращения заболеваний и особенностях взаимодействия с клиниками. [1].

БД также будет содержать: классификацию препаратов (включая взаимодействия и инструкции по применению); параметры диагностических процедур; перечень методов и инструментов для минимизации медицинских рисков.

Применение *ИИ-технологий* в такой системе выходит за рамки простого анализа данных — она способна прогнозировать состояние здоровья

на основе изображений, оптимизировать фармакологические рекомендации и предотвращать осложнения. Интеллектуальные алгоритмы автоматически адаптируют рекомендации в реальном времени, выявляют скрытые патологии на ранних стадиях и разрабатывают планы профилактического обслуживания.

Перспективы развития системы связаны с внедрением технологий машинного обучения и прогнозирования. Это обеспечит переход от пассивного реагирования к активным стратегиям, снижая эксплуатационные издержки и продлевая срок службы оборудования. Например, предсказание ухудшения состояния пациента или выявление патологических изменений на ранних стадиях позволит заранее адаптировать лечебные процедуры.[2].

Цель работы – разработка интеллектуальной системы, предоставляющей рекомендации по фармакологии и распознаванию состояний по фото лица, с использованием *RAG-подхода* для анализа медицинских данных. В основу проектирования положены принципы модульности, безопасности и адаптивности, а также научный подход к анализу данных и поиску технических решений.

Задачи исследования:

– изучение современных технологий в области медицинских ассистентов;

– формирование требований к интеллектуальной системе;

– проектирование архитектуры с учётом *RAG-методов*;

– оценка эффективности разработанного решения.

1 АНАЛИЗ

1.1 Анализ предметной области

Разрабатываемая система оперирует в трёх ключевых предметных областях, которые составят ядро её базы знаний и функционала.

Фармакотерапия и клинические рекомендации - это ядро текстового модуля. Область включает: классы лекарственных препаратов (антибиотики, антигистаминные и пр.), их показания, противопоказания, побочные эффекты, лекарственные взаимодействия и стандартные схемы приёма. Источниками данных для прототипа выступают открытые клинические рекомендации и агрегированные медицинские базы. Основная сложность — приведение неструктурированных текстовых данных к формату, пригодному для запроса к LLM, что решается использованием RAG-подхода. [3]

Визуальная диагностика по наблюдаемым признакам - это основа модуля анализа изображений. Область фокусируется на внешних, видимых на лице признаках, которые могут коррелировать с определёнными состояниями: цвет кожи (бледность, желтушность), отёчность (периорбитальные отёки), состояние кожных покровов (сыпь, эритема), признаки усталости (тёмные круги). Важно отметить, что система не ставит диагноз, а даёт предварительное заключение о возможных отклонениях от нормы, требующих внимания специалиста. Данные для обучения и настройки агентов берутся из открытых датасетов медицинских изображений и исследований по компьютерному зрению. [4]

Третий пласт — это форматы и стили коммуникации. С одной стороны, система должна понимать краткие и неформальные описания симптомов от обычных пользователей ("болит голова и тошнит"). С другой — работать с элементами структурированных эпикризов, извлекая из них сущности (диагнозы, препараты, процедуры). Эта область требует реализации механизмов предобработки текста и контекстуального поиска в медицинской терминологии.

1.2 Постановка задачи

Основная проблема в работе медицинских специалистов — высокий объем рутинной работы с неструктурированными данными: расшифровка анализов, подбор препаратов с учетом противопоказаний, первичный анализ визуальных симптомов. Существующие решения часто узкоспециализированы: одни работают только с изображениями, другие — только с документацией, третьи предоставляют общие рекомендации без глубокого анализа. Отсутствует интегрированная система, которая объединила бы

анализ текстовой медицинской информации с применением RAG для точности и анализ визуальных признаков в едином интерфейсе, доступном как врачам, так и пациентам для первичной консультации.[5]

Ещё одной проблемой, замедляющей работу медицинских специалистов, является необходимость одновременной работы с разрозненными типами данных:

Неструктурированными текстами: описания симптомов от пациентов, эпикризы, истории болезни, требующие ручного анализа для подбора терапии.

Визуальной информацией: фотографии пациентов, по которым требуется провести первичную оценку состояния.

Существующие цифровые решения, как правило, узко специализированы: одни системы автоматизируют документирование, другие помогают анализировать снимки. Однако они не решают задачу комплексной поддержки, когда врач нуждается в анализе и текстовой, и визуальной информации в рамках одного случая.

Таким образом, актуальность проекта обусловлена потребностью в гибридном инструменте, который в едином интерфейсе объединит функции анализа текстовых запросов и визуальной информации для ускорения и поддержки принятия решений на начальном этапе.[6]

Цель проекта — разработка прототипа интеллектуального медицинского ассистента, предоставляющего два типа услуг:

Текстовый ассистент: персонализированные фармакологические рекомендации на основе анализа симптомов, с уточняющим диалогом, реализованные через локальную LLM.

Визуальный ассистент: предварительный анализ возможных состояний по фотографии лица с использованием многоагентной системы.

Ключевая задача — создать модульную систему с автоматическим маршрутизированием запросов (текст - для фармакотерапии, фото - для анализа лица) и интуитивным веб-интерфейсом.

1.3 Требования к решению

Технологические аспекты.

Требования к системе сформулированы исходя из её двух основных функций: обработки текстовых запросов для фармакологических рекомендаций и анализа фотографий для предварительной оценки состояния. Основной акцент сделан на создании работоспособного прототипа, а не на описании гипотетических возможностей масштабной коммерческой системы.[7]

Технологической основой системы является микросервисная архитектура, которая позволяет логически разделить функциональные модули. Это обеспечивает независимую разработку и масштабирование компонентов.

Веб-интерфейс реализуется на базе фреймворка Next.js с использованием TypeScript. Для серверной части используются Node.js для организации API и оркестрации, а также Python для компонентов, работающих с машинным обучением. Выбор локальной языковой модели (LLM), развернутой через Ollama, обусловлен требованием конфиденциальности данных и независимости от внешних облачных сервисов, что критически важно для медицинской сферы. Для работы с текстовыми медицинскими данными применяется подход RAG (Retrieval-Augmented Generation), при котором ответы генерируются на основе релевантных фрагментов из внутренней базы знаний, что повышает достоверность рекомендаций по сравнению с использованием генеративной модели в чистом виде.

Безопасность в рамках прототипа обеспечивается базовыми, но достаточными мерами. Доступ к системе защищается механизмом регистрации и аутентификации с хешированием паролей и использованием JWT-токенов для управления сессиями. Все данные передаются по защищенному протоколу HTTPS (TLS). Конфиденциальная пользовательская информация, включая тексты диалогов, хранится в базе данных PostgreSQL в зашифрованном виде. Полный цикл развертывания и воспроизводимость среды обеспечиваются за счет контейнеризации с использованием Docker.

Эксплуатационные требования ориентированы на типичные условия использования прототипа. Система должна стабильно работать на стандартных персональных компьютерах и ноутбуках. Время отклика на запрос (генерация рекомендации или анализа изображения) в пределах 10-30 секунд считается приемлемым для интерактивного диалога. Архитектура предусматривает возможность дальнейшего масштабирования — например, вынос ресурсоемкого модуля работы с LLM на отдельный выделенный сервер при росте нагрузки. [8]

Функциональные характеристики системы.

Система предоставляет два основных функционала, доступных через единый чат-интерфейс.

Формирование рекомендаций по фармакотерапии на основе текстового описания симптомов. Пользователь вводит жалобы или описание состояния в свободной текстовой форме. Система, используя локальную языковую модель (LLM), запущенную через Ollama, анализирует запрос, определяет предполагаемое заболевание и выявляет недостающие для формирования рекомендации данные (например, возраст, аллергии, принимаемые препараты). При необходимости система запрашивает эти данные у пользователя в формате уточняющих вопросов, после чего генерирует текстовые рекомендации по терапии, включая возможные препараты и общие указания. Все сообщения сохраняются в истории диалога.[9]

Анализ фотографии лица и генерация предварительного заключения. Пользователь загружает или делает снимок через интерфейс. Система

автоматически направляет его на обработку в модуль анализа изображений. Обработка выполняется последовательной цепочкой (пайплайном) из нескольких агентов. Первый агент проверяет наличие лица на изображении и его пригодность для анализа. Второй агент формирует структурированное текстовое описание визуальных признаков (например, цвет кожи, наличие отеков, высыпаний). Третий агент на основе этого описания генерирует итоговое текстовое заключение о возможных корреляциях выявленных признаков с определенными состояниями. Если лицо на фото не обнаружено, пользователь получает соответствующее сообщение об ошибке.[10]

Управление контекстом и данными. Система поддерживает создание и хранение множества независимых чатов (диалогов), что позволяет вести отдельные обсуждения для разных случаев или пациентов. Полная история переписки внутри каждого чата сохраняется в базе данных и загружается при повторном открытии, обеспечивая непрерывность диалога. Для доступа к функциям предусмотрены регистрация и аутентификация пользователя.

1.4 Анализ аналогов

Radex — это российская интеллектуальная система поддержки принятия врачебных решений, разработанная специалистами Пензенского государственного университета. Платформа предназначена для автоматизированного анализа рентгенографических изображений и выявления патологических изменений (на рисунке 1.1 представлено интерфейсное окно системы Radex). Система используется в клинической практике для ускорения интерпретации рентгеновских снимков и повышения точности диагностики заболеваний лёгких и других патологий.

Среди ключевых достоинств Radex следует отметить высокую точность анализа визуальных медицинских данных, обеспечиваемую применением современных моделей компьютерного зрения. Платформа интегрируется с существующими медицинскими информационными системами, что облегчает её внедрение в рабочие процессы. Система также позволяет снизить нагрузку на специалистов, автоматизируя часть рутинных задач, связанных с первичной интерпретацией изображений.

Несмотря на преимущества, Radex имеет и существенные ограничения. В частности, система ориентирована исключительно на работу с изображениями и не поддерживает анализ текстовой медицинской документации, включая эпикризы или отчёты врачей. Платформа не использует RAG-подход и не взаимодействует с внешними источниками знаний для динамического уточнения информации. Кроме того, Radex не предоставляет функциональности для анализа лекарственных взаимодействий или формирования фармакологических рекомендаций, что ограничивает её применение в более широких сценариях клинической поддержки.

Рисунок *1.1* – Главная страница сайта Radex

Suki AI — это коммерческий цифровой медицинский ассистент, представленный на официальном сайте компании Suki и широко используемый в клинической практике США (На рисунке 1.2 представлено изображение главной страницы сайта Suki AI). Платформа предназначена для автоматизации рутинных административных процессов, включая ведение медицинской документации, заполнение электронных медицинских карт и обработку голосовых команд врача.

Среди ключевых достоинств системы можно выделить высокую точность распознавания речи, обеспечивающую корректное формирование клинических записей на основе устных замечаний врача. Платформа интегрируется с распространёнными системами электронных медицинских карт (EHR), что позволяет уменьшить время на заполнение документации и повысить эффективность работы специалиста. Кроме того, Suki AI поддерживает генерацию шаблонов отчётов и адаптацию к индивидуальному стилю ведения записей конкретного врача.

Несмотря на широкие возможности, платформа имеет и ряд ограничений. Suki AI не выполняет глубокого анализа текстовых медицинских документов и не поддерживает обработку эпикризов в автоматическом режиме. Система не предоставляет механизмов фармакологического анализа, таких как проверка взаимодействий лекарственных средств или подбор схем терапии. Также отсутствует поддержка RAG-подхода, что ограничивает способность динамически расширять знания ассистента за счёт внешних источников медицинской информации.

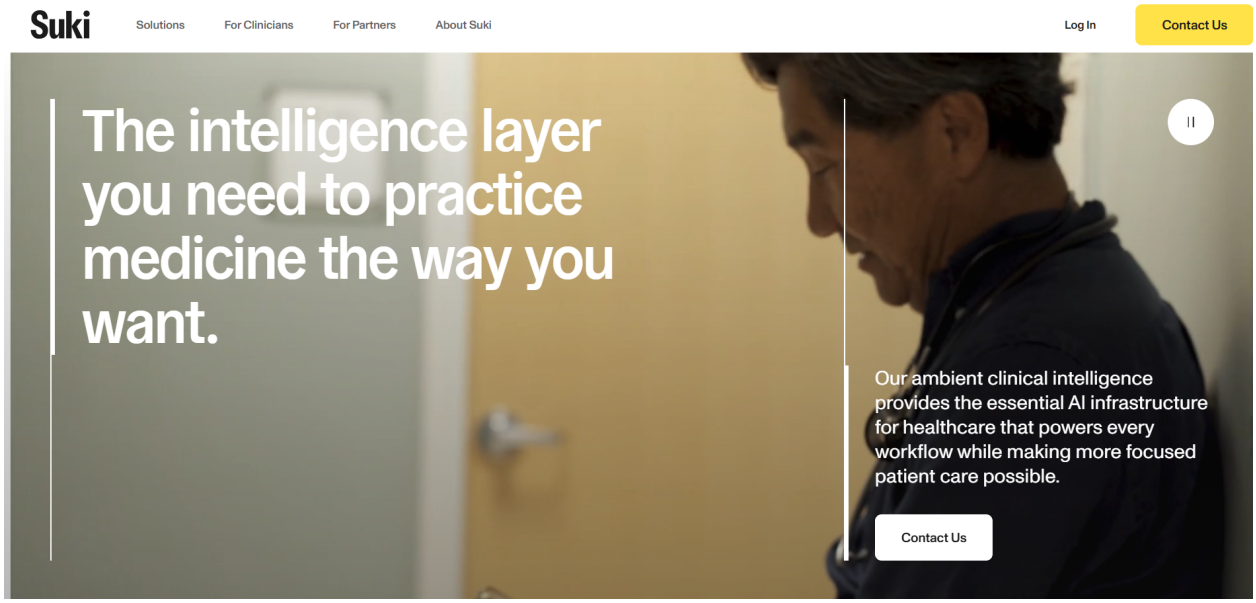

Рисунок *1.2* – Главная страница сайта Suki AI

UpToDate — это международная клиническая система поддержки принятия врачебных решений, предоставляемая одноимённой компанией Wolters Kluwer и широко используемая в медицинских учреждениях по всему миру (На рисунке 1.3 представлено изображение главной страницы сайта UpToDate). Платформа содержит обширную структурированную базу медицинных знаний, включающую диагностические протоколы, клинические рекомендации, фармакологические гиды и обзоры доказательной медицины.

К ключевым достоинствам UpToDate относится высокая достоверность информации, обеспечиваемая экспертной валидацией и регулярным обновлением базы данных. Платформа предоставляет клинические рекомендации, основанные на актуальных научных исследованиях, а также интегрируется с системами электронных медицинских карт (EHR), что позволяет врачу оперативно получать доступ к данным пациента и сопоставлять их с клиническими протоколами. Значимой особенностью является встроенный фармакологический модуль, обеспечивающий проверку лекарственных взаимодействий, корректировку дозировок и формирование терапевтических рекомендаций.

Несмотря на широкие функциональные возможности, UpToDate имеет и ряд ограничений. Платформа ориентирована на ручной поиск информации и не выполняет автоматизированный анализ медицинских текстов, таких как эпикризы или заключения специалистов. Система не поддерживает обработку неструктурированных данных и не использует RAG-подход для динамической контекстной генерации ответов на основе внешних источников. Кроме того, UpToDate не предоставляет персонализированных выводов на основе конкретной медицинской документации пациента, возла-

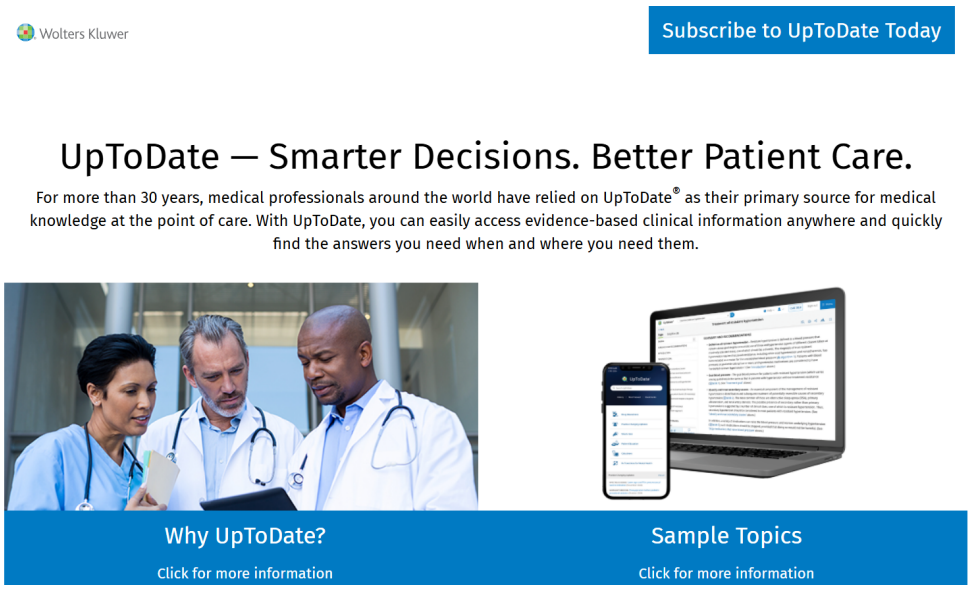

Рисунок *1.3* – Главная страница сайта UpToDate

гая интерпретацию материалов на самого специалиста.

Сравнительный анализ.

Сравнительный анализ показывает, что рассмотренные системы обладают различной функциональной направленностью. Radex демонстрирует высокую эффективность при обработке рентгенографических изображений, но не поддерживает анализ текстовой медицинской документации. Suki AI автоматизирует процесс ведения документации, однако не выполняет глубокую интеллектуальную обработку текстов и не формирует клинические заключения. UpToDate предоставляет обширную клиническую базу знаний и фармакологическую поддержку, но не выполняет автоматический анализ эпикризов и не использует RAG-подход. Таким образом, ни один из аналогов полностью не удовлетворяет требованиям проекта интеллектуального ассистента, ориентированного на анализ текстовых медицинских данных и формирование персонализированных рекомендаций.

Требования	**Radex**	**Suki AI**	**UpToDate**
Анализ текстовых медицинских документов	×	✓	✓
Фармакологические рекомендации	×	×	✓
Использование RAG-подхода	×	×	×

Таблица *1.1* – Таблица соответствия требованиям.

1.5 Анализ подходов к решению проблемы

После анализа существующих аналогов и их недостатков становится необходимым разработать систему, способную обрабатывать неструктурированные медицинские данные, поддерживать анализ эпикризов и изображений, обеспечивать безопасность и удобство использования. Ниже рассмотрены возможные подходы к реализации медицинского ассистента. [11]

Универсальный доступ через облачную веб-платформу

Данный подход предполагает разработку веб-системы с чат-интерфейсом, работающей в браузере и доступной с любых устройств. Основной акцент делается на универсальности доступа и возможности использования как врачами, так и пациентами.

Ключевыми преимуществами являются кроссплатформенность, отсутствие необходимости установки, централизованные обновления, а также возможность масштабирования в облаке. Веб-интерфейс позволяет интегрировать полный стек функций: анализ текста, RAG-поиск, фармакологические подсказки, загрузку изображений и работу со структурированными данными.

Подход обеспечивает минимальный порог входа, гибкую интеграцию с медицинскими учреждениями и соответствие нормам безопасности за счёт серверной обработки данных.

Специализированная профессиональная система для рабочих мест врача

Этот подход ориентирован на создание настольного приложения, предназначенного исключительно для медицинских специалистов. Он делает акцент на тесной интеграции с локальными системами, внутренними сетями и периферийными устройствами.

Преимуществом является возможность работать с локальными данными, PACS-серверами, медицинским оборудованием и внутренними EHR-системами. Однако доступ ограничивается рабочими станциями учреждения, что снижает гибкость и масштабируемость. Обновления ПО требуют ручного или централизованного развёртывания, что усложняет сопровождение.

Подход эффективен для узкого профессионального использования, но не подходит для широкой аудитории и затрудняет оперативное расширение функциональности.

Коммуникационный ассистент в экосистеме мессенджера

Этот вариант предполагает создание ассистента в формате чат-бота в мессенджере. Основной упор делается на быстроту доступа и повышенную пользовательскую вовлечённость.

Достоинствами являются высокая скорость запуска, отсутствие необходимости в обучении работе с системой и возможность взаимодействия через привычный интерфейс. Однако такой подход имеет существенные ограничения: низкий уровень контроля над безопасностью, отсутствие сертифицированных протоколов обработки медицинских данных, ограниченные возможности интеграции с локальными системами и неадаптированность платформы к сложным аналитическим задачам.

Данный вариант подходит прежде всего для пользователей-пациентов, но не удовлетворяет требованиям медучреждений по безопасности и функциональности.

1.6 Вывод

Анализ предметной области и существующих решений показал, что ни одна из рассмотренных систем не обеспечивает комплексной обработки неструктурированных текстовых медицинских данных и визуальной информации в едином контуре, а также не использует RAG-подход для повышения достоверности фармакологических рекомендаций. Существующие инструменты ориентированы на узкие задачи — анализ изображений, ведение документации или доступ к статическим клиническим базам — и не поддерживают модульную интеграцию разнородных данных.

Проведённый сравнительный анализ подтвердил отсутствие решений, сочетающих локальную языковую модель, механизм контекстного поиска и многоагентную обработку изображений. Выявленный функциональный разрыв обосновывает необходимость разработки архитектуры, обеспечивающей автоматическое маршрутизирование запросов, персонализированную интерпретацию текстовой информации и формирование структурированных заключений на основе визуальных признаков.

Таким образом, результаты анализа подтверждают корректность выбранного технического подхода и необходимость создания прототипа интеллектуального ассистента, объединяющего оба типа входных данных в единой системе. Полученные выводы формируют основание для дальнейшего расширения функциональности и интеграции решения в клиническую инфраструктуру.

2 ПРОЕКТИРОВАНИЕ

Система представляет собой веб-приложение для формирования медицинских рекомендаций, в котором взаимодействие осуществляется через чат-интерфейс. Определение сценария обработки выполняется автоматически и основывается исключительно на наличии или отсутствии фотографии в сообщении. Если пользователь отправляет только текст, система направляет данные в модуль фармакотерапии, реализованный на основе локальной LLM-модели, запускаемой через Ollama. Перед формированием терапевтического результата модель выполняет этап уточнения: определяет предполагаемое заболевание по описанным симптомам, выявляет возможные противопоказания и при необходимости запрашивает недостающие сведения. Диалоговый режим доступен только внутри текстовой фармакотерапии, что позволяет пользователю получать альтернативные варианты терапии или корректировать исходную информацию.

При отправке изображения запрос автоматически направляется в многоагентную подсистему анализа лица. Работа подсистемы включает три последовательных этапа. На первом агент проверяет наличие лица на изображении и формирует текстовое описание визуальных признаков. На втором агент интерпретирует полученное описание и вычисляет вероятностное распределение возможных заболеваний. На третьем этапе генерируется итоговый текстовый вывод, основанный на результатах предыдущих агентов. Если лицо на изображении отсутствует, дальнейшая обработка не выполняется, и пользователю возвращается соответствующее уведомление.

Фронтенд приложения разработан с использованием Next.js, TypeScript и классического CSS. Клиентская часть обеспечивает отображение чат-интерфейса, управление списком чатов и выполнение операций регистрации и аутентификации. Данные авторизации хранятся как в локальном хранилище браузера (localStorage), так и на сервере. Для серверной аутентификации используется JWT-токен, который возвращается после успешного входа и применяется при последующих запросах. Коммуникация между фронтендом и сервером осуществляется через REST API. История сообщений каждого чата сохраняется в базе данных и загружается при открытии соответствующего диалога, обеспечивая восстановление контекста при повторных обращениях. Фронтенд-приложение и подсистема анализа лица размещены внутри одного Docker-образа как независимые сервисы, тогда как модуль фармакотерапии работает локально и вызывается отдельно.

На диаграмме прецедентов(рисунок 2.1) отражена основная функциональность системы с точки зрения взаимодействия пользователя с веб-интерфейсом. Актор «Пользователь» выполняет следующие ключевые действия:

– создание нового чата (ВИ-1);

– регистрация и вход в аккаунт (ВИ-3 и ВИ-2);

– просмотр и выбор существующего чата из списка (ВИ-5 и ВИ-9);

– просмотр истории чата (ВИ-4);

– отправка текстового сообщения в активном чате (ВИ-6), так же включается прецедент «Загрузить фото» (ВИ-7) и «Сделать фото» (ВИ-8), пользователь может загрузить фото лица у устройства или сделать фото в приложении и отправить его вместе с текстом для получения рекомендаций. Отправив только текст, пользователь получает фармакотерапию.

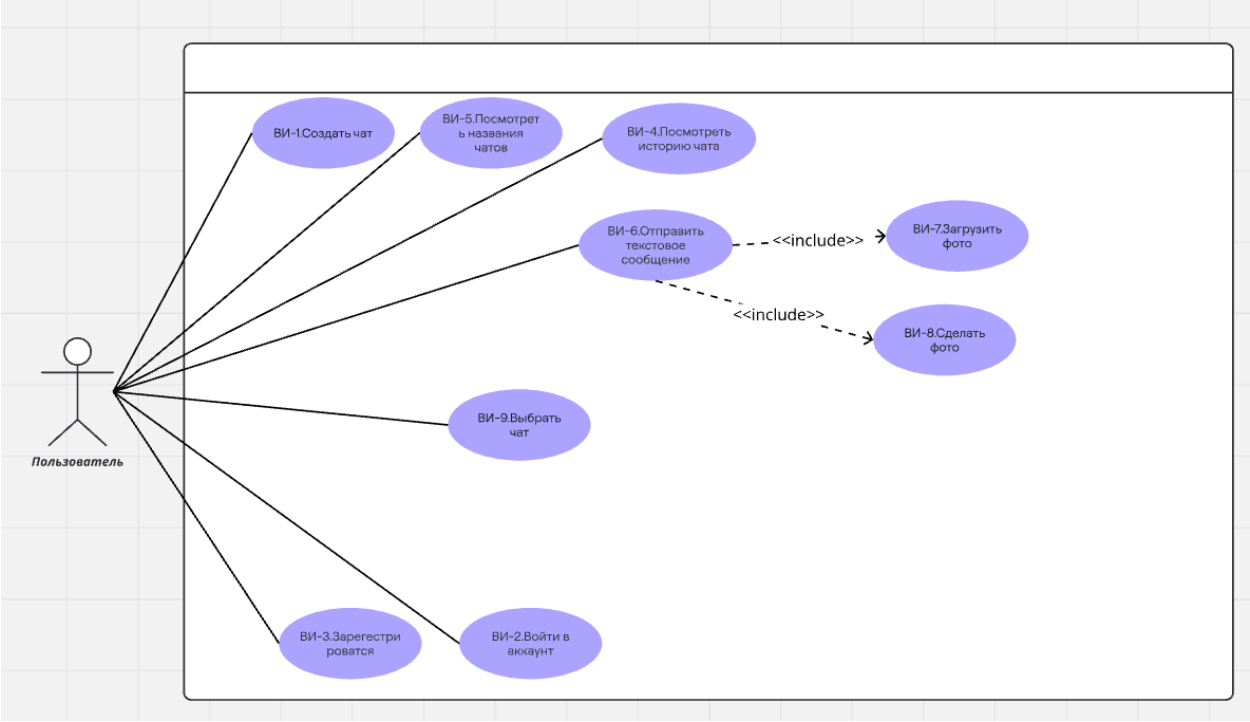

Рисунок *2.1* – Диаграмма прецедентов системы медицинских рекомендаций

Диаграмма состояний(рисунок 2.2) пользовательского интерфейса описывает жизненный цикл приложения с момента запуска до завершения работы пользователя. Выделены следующие основные состояния:

– UI-Регистрация — начальное состояние неавторизованного пользователя;

– UI-Войти в аккаунт — состояние если пользователь хочет войти в аккаунт;

– UI-Чат — состояние просмотра истории первого чата в списке, если пользователь только создал чат, первый чат создается автоматически;

– UI-Список чатов — состояние в котором пользователь может как создать новый чат, так и выбрать один из существующих;

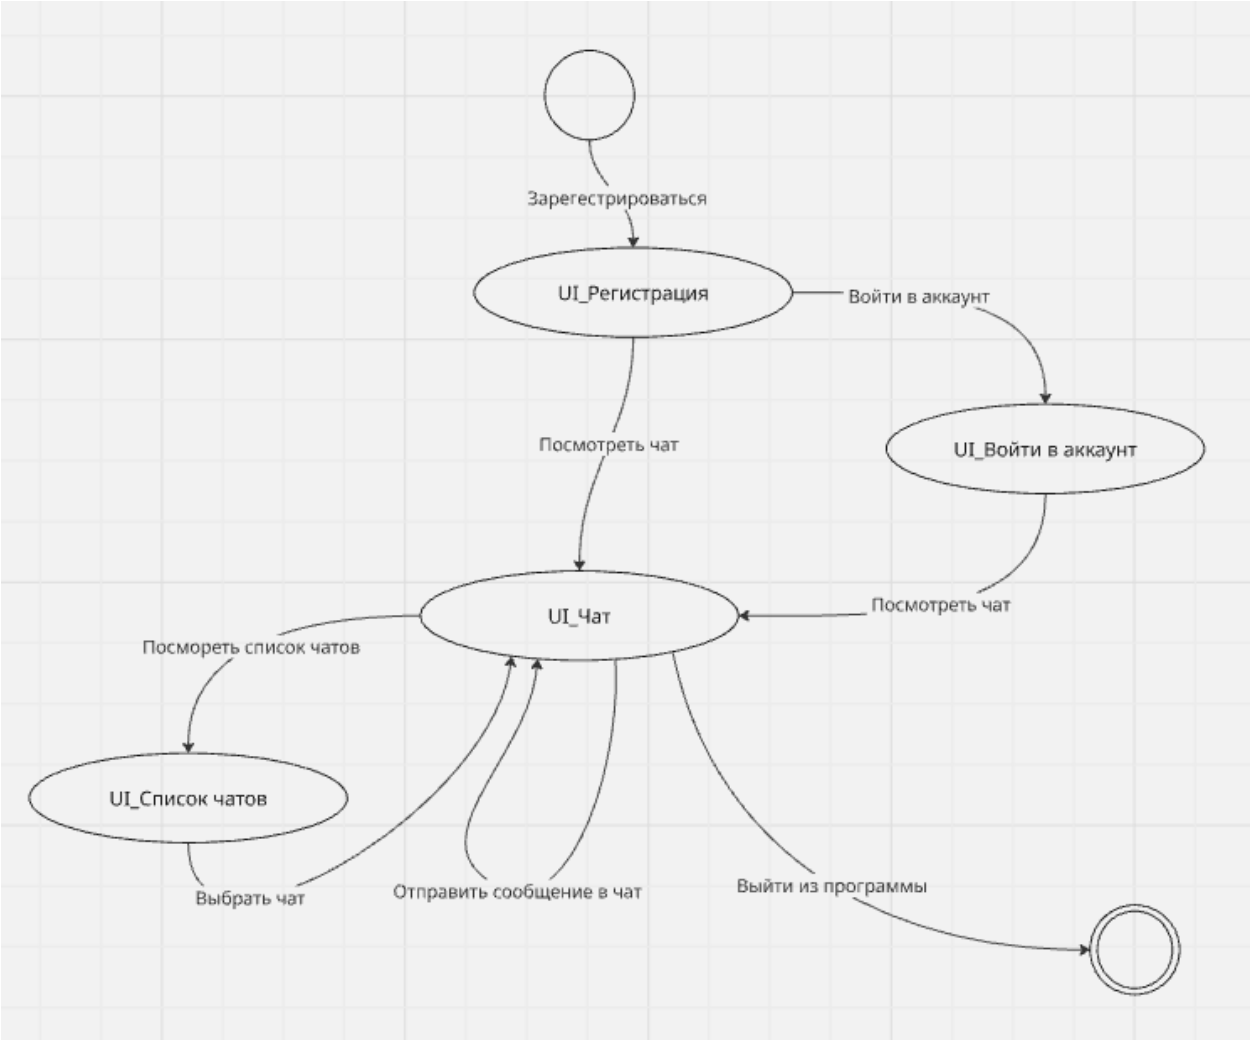

Рисунок *2.2* – Диаграмма состояний пользовательского интерфейса

BPMN-диаграмма обработки сообщения с фотографией (рисунок 2.3) иллюстрирует полный цикл анализа изображения лица. Процесс начинается с проверки наличия активного чата. При его отсутствии пользователь может создать новый чат, после чего переходит к отправке сообщения. Пользователь прикрепляет фотографию (либо загружает файл, либо делает снимок через камеру устройства) и сопровождает её текстовым описанием. Далее система выполняет проверку: содержит ли изображение лицо человека. Если лицо не обнаружено, сразу формируется и отправляется пользователю сообщение об ошибке. При успешном обнаружении лица запускается многоагентная подсистема: первый агент проверяет качество изображения и формирует детальное текстовое описание визуальных признаков, второй агент интерпретирует полученное описание и определяет вероятностные заболевания, третий агент консолидирует данные предыдущих шагов и генерирует итоговый медицинский вывод. Готовый текстовый ответ сохраняется в базе данных как часть истории чата и отображается пользователю в интерфейсе.

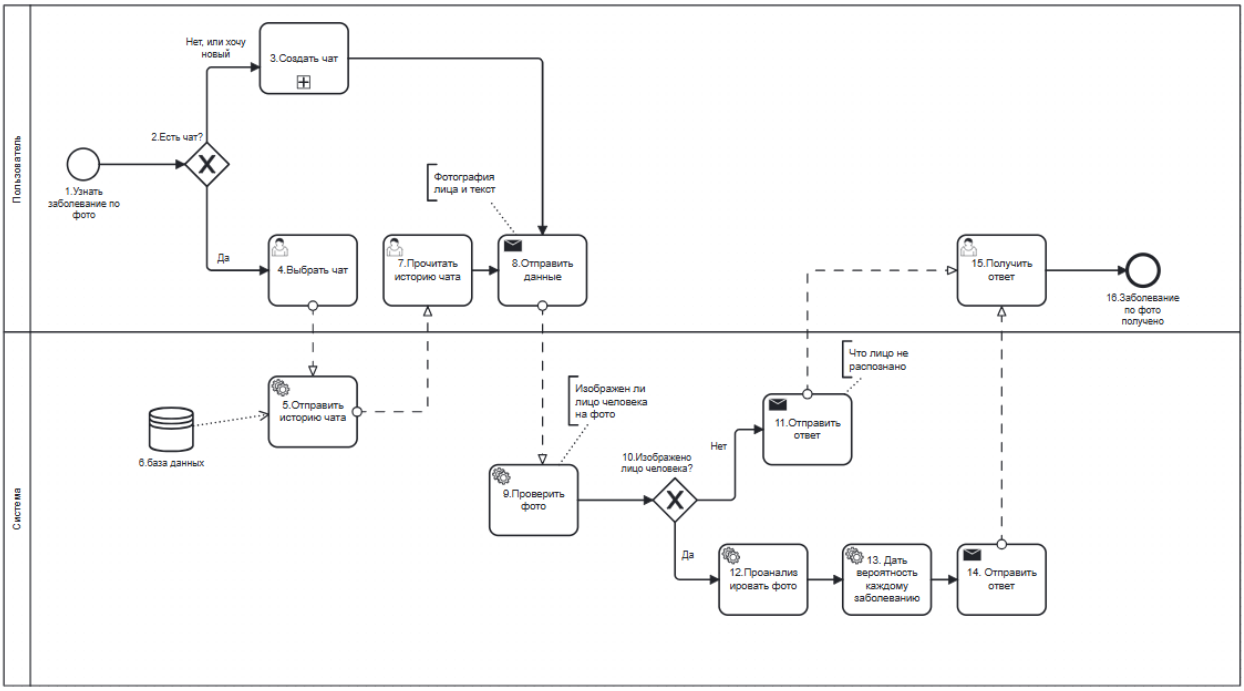

Рисунок *2.3* – BPMN-диаграмма обработки сообщения с фотографией лица

BPMN-диаграмма формирования фармакотерапии по текстовому запросу (рисунок 2.4) описывает процесс обработки сообщений, содержащих только текст. После выбора или создания чата пользователь вводит описание симптомов или жалобы. Сообщение отправляется на сервер, где локальная языковая модель (через Ollama) анализирует текст и определяет предполагаемое заболевание. Далее модель автоматически проверяет наличие противопоказаний и недостающих данных. Если требуются уточнения (например, возраст, сопутствующие заболевания, аллергии, принимаемые препараты), система формирует и отправляет уточняющий вопрос пользователю, после получения ответа цикл повторяется. При достаточности информации модель генерирует вариант фармакотерапии, сохраняет его в базе данных как часть истории чата и выводит пользователю в виде структурированного текстового ответа. Процесс завершается либо выдачей окончательной рекомендации, либо продолжением диалога для дальнейших уточнений в рамках того же чата.

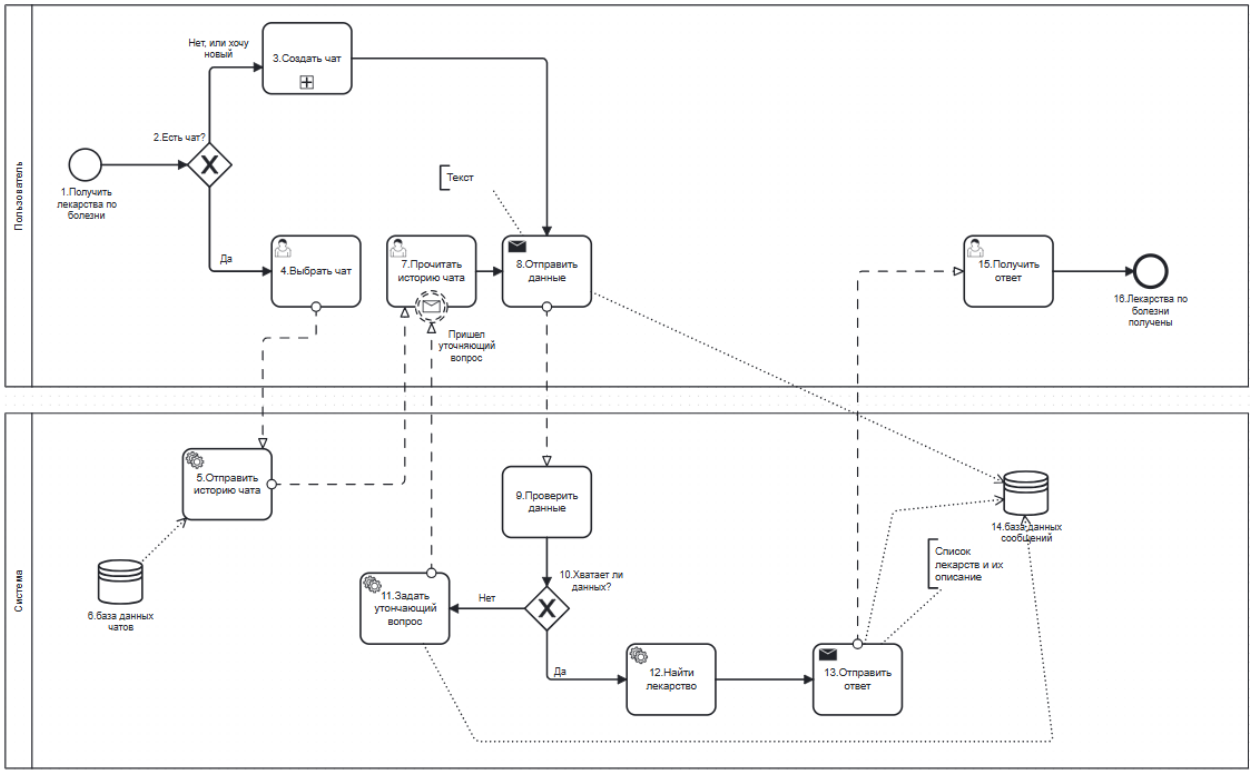

Рисунок *2.4* – BPMN-диаграмма формирования фармакотерапии по текстовому запросу

BPMN-диаграмма создания нового чата (рисунок 2.5) описывает процесс инициализации диалоговой сессии. Пользователь инициирует создание нового чата, после чего фронтенд запрашивает у пользователя желаемое название. Введённые данные передаются на сервер, где создаётся запись о новом чате, одновременно сохраняется в базе данных с привязкой к идентификатору текущего пользователя. После успешного сохранения сервер возвращает подтверждение, и фронтенд обновляет список доступных чатов, делая только что созданный чат активным для дальнейшего взаимодействия. Процесс завершается автоматическим переходом пользователя в интерфейс сообщений нового чата.

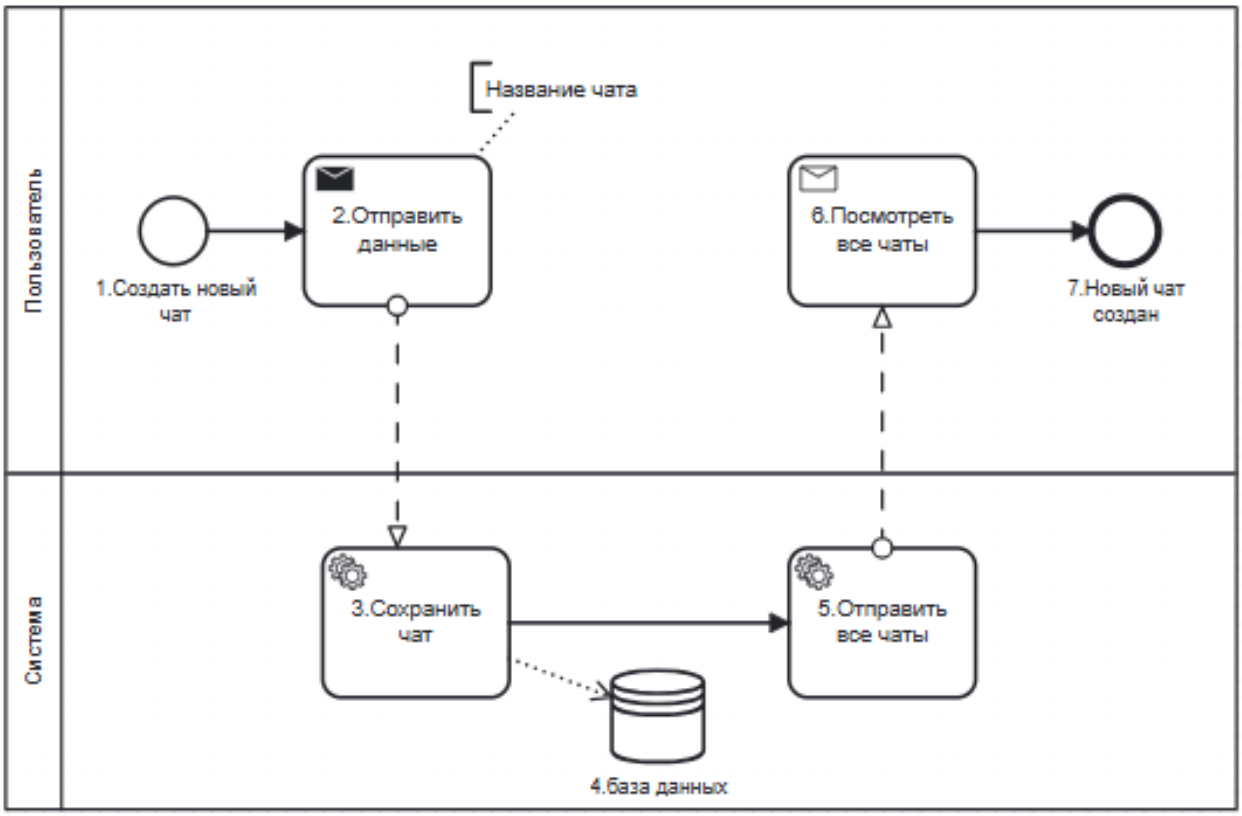

Рисунок *2.5* – BPMN-диаграмма создания нового чата

BPMN-диаграмма процесса регистрации пользователя (рисунок 2.6) иллюстрирует последовательность действий при первом входе в систему. Пользователь вводит адрес электронной почты, логин и пароль, после чего данные отправляются на сервер. Серверная часть проверяет корректность введённых данных и уникальность логина и адреса электронной почты. При обнаружении ошибки (некорректный формат или уже существующий пользователь) формируется сообщение об ошибке и возвращается клиенту. В случае успешной валидации создаётся новая запись пользователя в базе данных, генерируется уникальный идентификатор. После сохранения данных сервер отправляет клиенту идентификатор пользователя, фронтенд сохраняет идентификатор в localStorage и автоматически переводит пользователя в состояние просмотра чата.

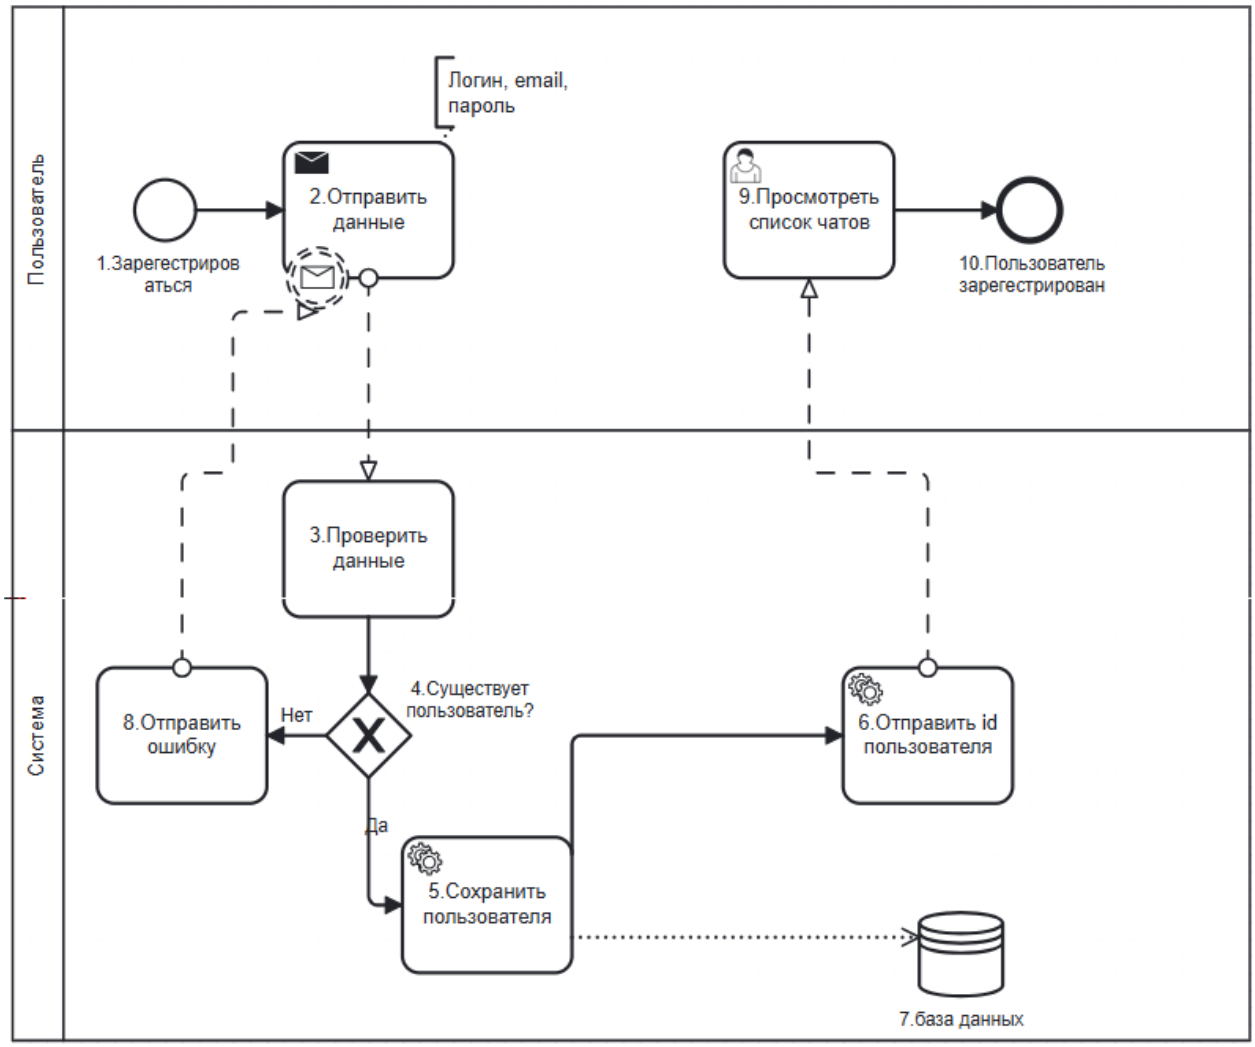

Рисунок *2.6* – BPMN-диаграмма регистрации пользователя

BPMN-диаграмма процесса входа в существующий аккаунт (рисунок 2.7) описывает аутентификацию ранее зарегистрированного пользователя. Пользователь вводит логин и пароль, данные передаются на сервер через защищённое соединение. Сервер проверяет соответствие введённой пары данным, хранящимся в базе. Если комбинация неверна, генерируется сообщение об ошибке и отправляется обратно. При успешной аутентификации сервер извлекает идентификатор пользователя и возвращает его клиенту вместе. Фронтенд сохраняет полученный идентификатор в localStorage, после чего автоматически переходит в состояние просмотра чата пользователя. Процесс завершается восстановлением контекста ранее созданных диалогов.

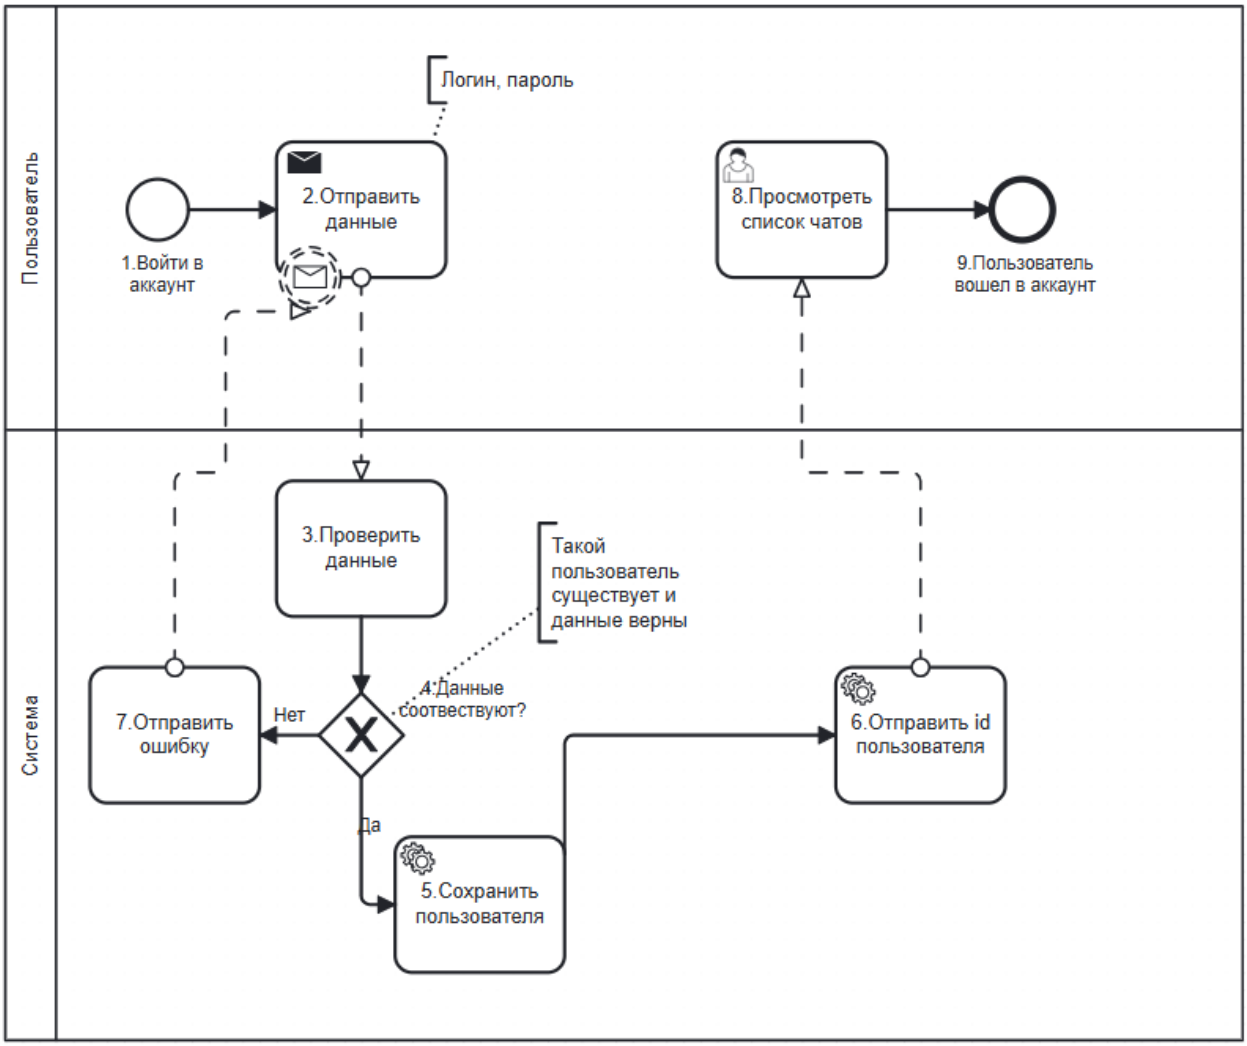

Рисунок *2.7* – BPMN-диаграмма входа в аккаунт

Диаграмма последовательности основных сценариев взаимодействия в чате (рисунок 2.8) иллюстрирует три ключевых потока обмена данными между пользователем, фронтендом (Next.js) и двумя backend-сервисами — Orchestration-service и Pharma-service.

Первый подпроцесс — загрузка конкретного чата: при клике на чат фронтенд выполняет GET-запрос к /api/chat/id, получает историю сообщений и отображает её в интерфейсе.

Второй подпроцесс — запрос рекомендаций по лицу: пользователь прикрепляет фотографию и отправляет сообщение. Фронтенд формирует POST-запрос к /api/chat/new/image, передавая файл изображения, текст промпта, идентификатор пользователя и идентификатор чата. Orchestration-service координирует работу агентов анализа лица и возвращает текстовый ответ (например, «Тёмные круги, отёчность, жирная кожа. . . »), который сразу сохраняется в истории и отображается пользователю.

Третий подпроцесс — запрос фармакотерапии: пользователь отправля-

ет текстовое сообщение через POST /api/v1/chat. Pharma-service (локальная LLM через Ollama), который может вернуть либо окончательный ответ, либо уточняющий вопрос. В примере система запрашивает противопоказания, фронтенд отображает вопрос как обычное сообщение от ассистента, и диалог продолжается в том же чате.

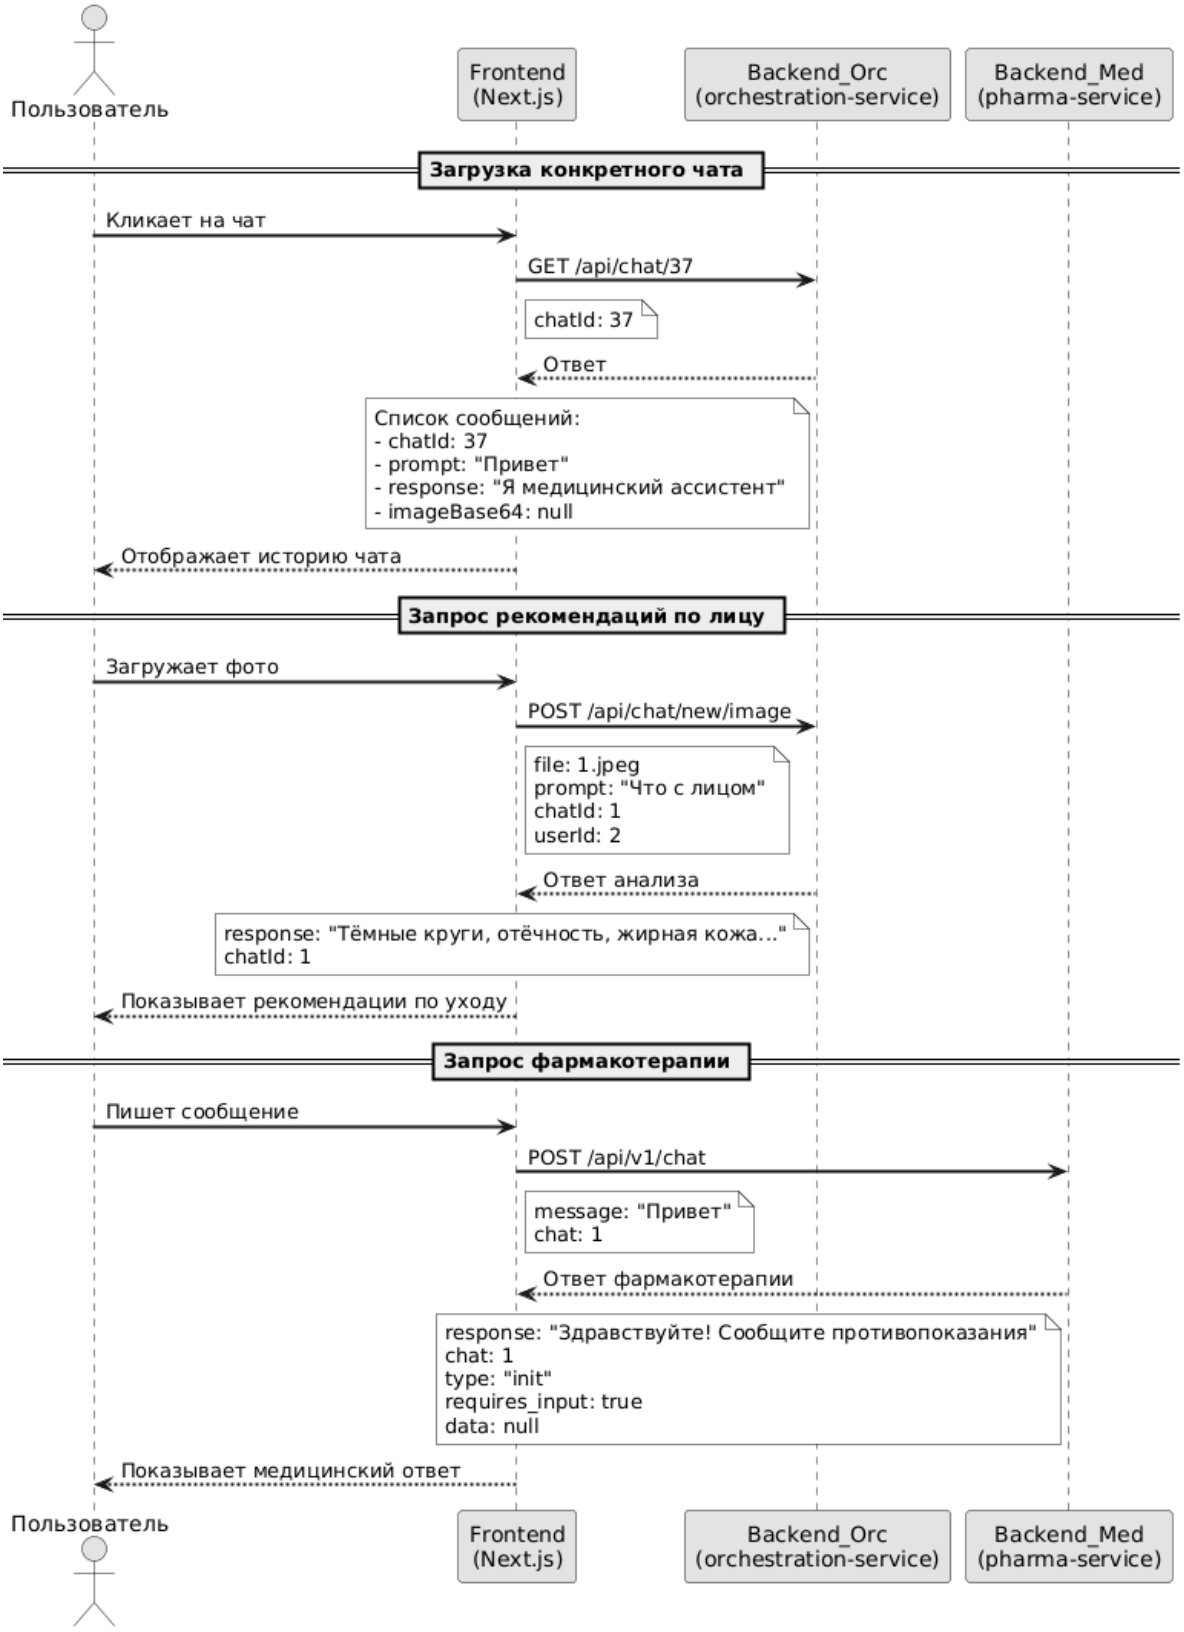

Рисунок *2.8* – Диаграмма последовательности основных сценариев работы чата

Диаграмма последовательности процессов регистрации, входа и инициализации чатов (рисунок 2.9) описывает взаимодействие пользовате-

ля с фронтендом и двумя backend-сервисами — authentication-service и orchestration-service.

При регистрации пользователь заполняет форму, фронтенд отправляет POST /api/auth/register с данными (username, password, email). Сервис валидирует данные и создаёт запись в базе, возвращая полные данные пользователя (включая даты создания/обновления).

При входе в аккаунт выполняется POST /api/auth/login с логином и паролем. В ответ приходит JWT-токен и userId, userId сохраняется в localStorage.

После успешной аутентификации пользователь нажимает «Новый чат» — фронтенд отправляет POST /api/chat/create с названием чата и userId. Orchestration-service создаёт запись и возвращает chatId.

Далее при открытии боковой панели фронтенд выполняет GET /api/chat/list, получая полный список чатов текущего пользователя с их идентификаторами и названиями.

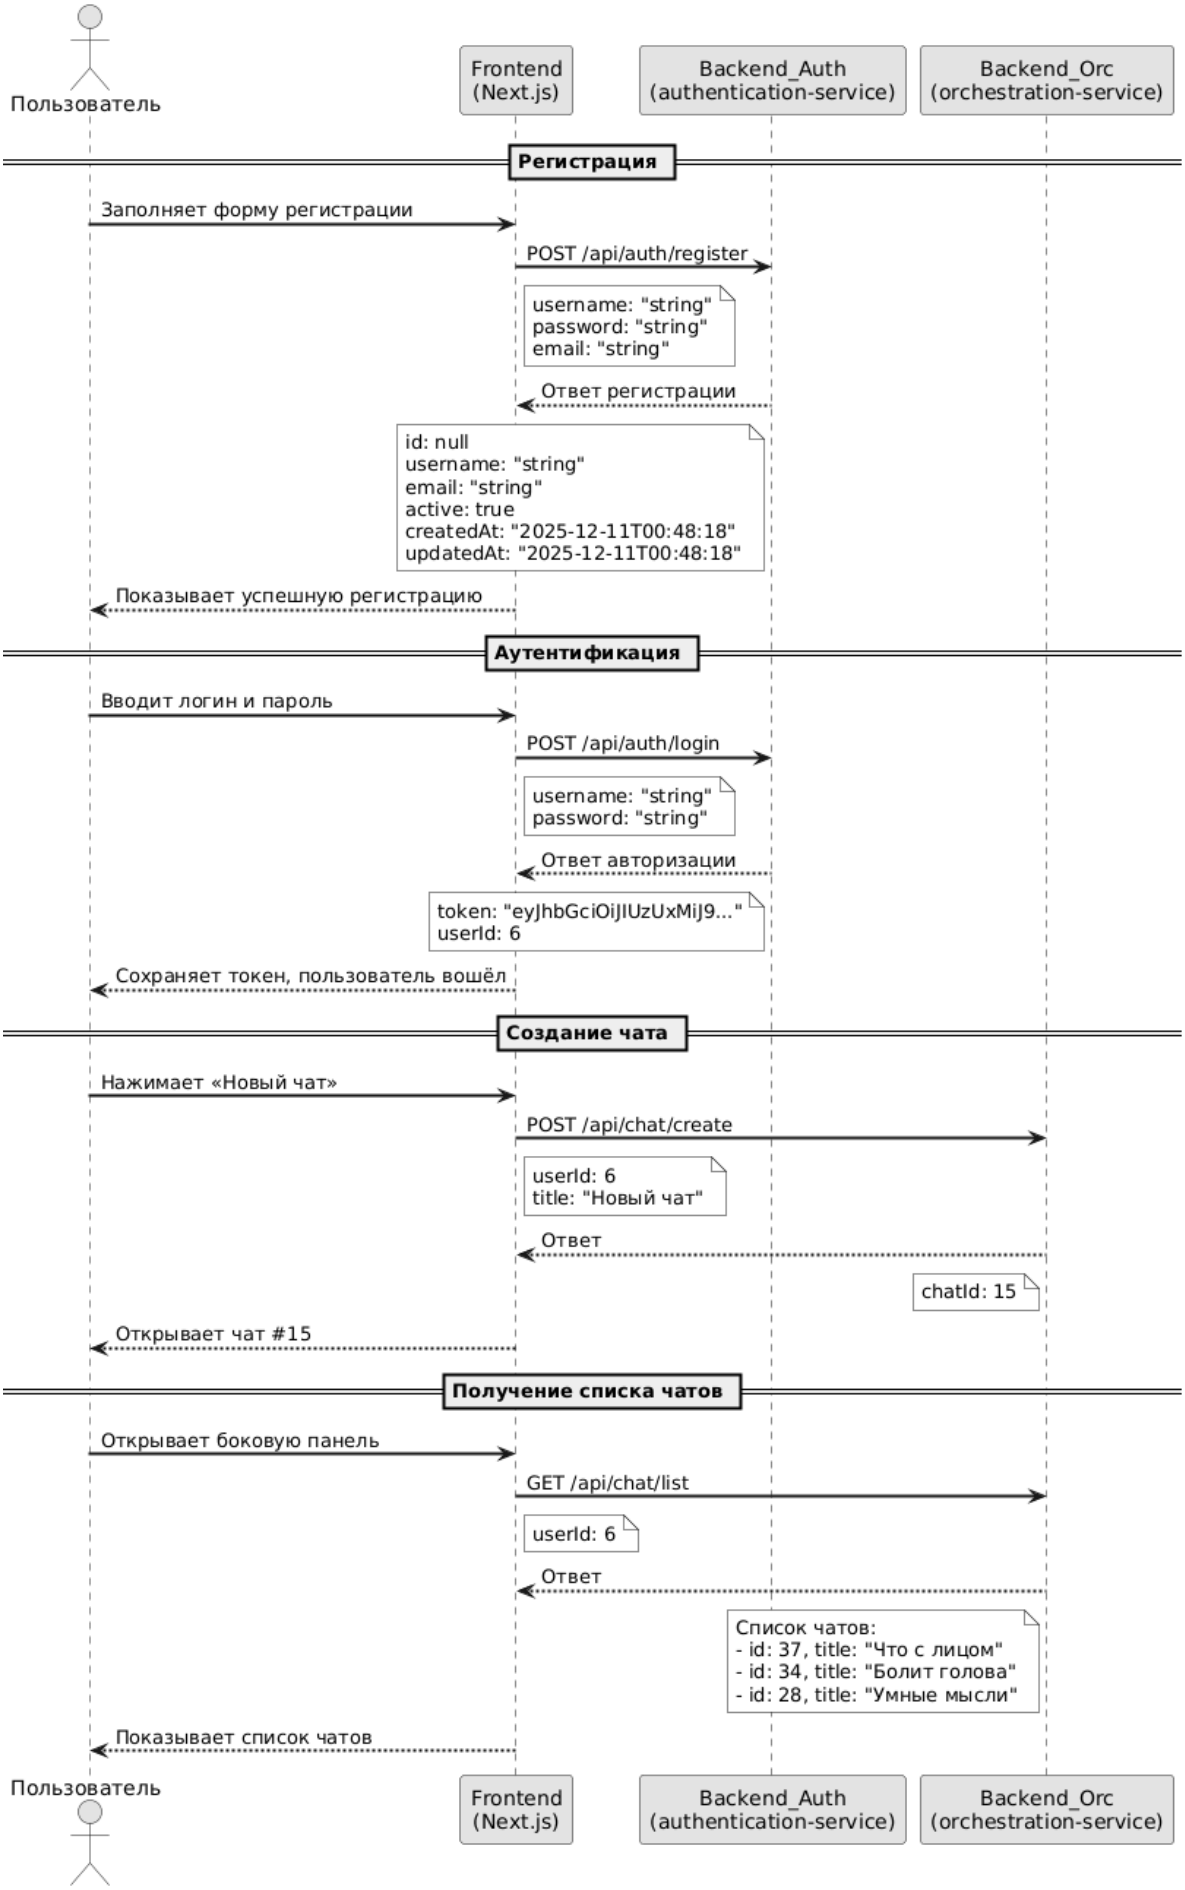

Рисунок *2.9* – Диаграмма последовательности регистрации, входа и инициализации чатов

2.1 Анализ пользователей

Анализ пользовательской аудитории системы позволяет выделить две основные группы, отличающиеся целями и особенностями взаимодействия с приложением. В центре рассмотрения находится пользователь, работающий с системой через чат-интерфейс, который обеспечивает доступ к текстовой фармакотерапии и обработке изображений лица.

Первая группа — медицинские специалисты. Их мотивация связана с необходимостью оперативного получения вариантов фармакотерапии без ручного подбора препаратов и дозировок. Взаимодействие преимущественно сосредоточено на текстовых запросах, где важна точность результата и наличие механизма уточнения входных данных. Поведение таких пользователей характеризуется повторяемостью однотипных запросов и использованием диалогового режима для уточнения симптоматики и противопоказаний.

Вторая группа — обычные пользователи, которым требуется предварительная оценка состояния или ориентир перед обращением к врачу. Они используют как текстовые запросы, так и фотографии. Фотоанализ применяется для получения описания визуальных признаков и базовых рекомендаций по состоянию кожи или возможным отклонениям. Текстовый ввод используется для получения упрощённой фармакотерапии или альтернативных рекомендаций. Взаимодействие носит нерегулярный характер и предполагает получение кратких, понятных результатов без углублённого диалога.

Обе группы взаимодействуют с системой через единый интерфейс, однако их цели и сценарии использования различаются, что определяет требования к функциональности и модели обработки данных внутри приложения.

2.2 Вывод

Представленная архитектура описывает полный цикл обработки пользовательских запросов в условиях разделения логики на два независимых направления: текстовую фармакотерапию и анализ изображений лица. Автоматический выбор маршрута обработки на основе наличия фотографии обеспечивает единый сценарий взаимодействия, при котором различаются только внутренние механизмы генерации результата. Текстовые запросы обрабатываются локальной LLM-моделью с возможностью уточняющего диалога, тогда как фотообработка выполняется многоагентной подсистемой без обратных уточнений. Фронтенд реализован на Next.js и функционирует как интерфейс доступа ко всем процессам, обеспечивая работу с чатами, аутентификацией и историей сообщений. Использование отдельных backend-сервисов для оркестрации, аутентификации, анализа лица и формирования

терапии формирует чёткую модульную структуру взаимодействия. Анализ пользовательских категорий демонстрирует различие в целях использования системы: медицинские специалисты ориентируются на получение терапевтических схем, тогда как обычные пользователи — на предварительную оценку состояния и результаты фотоанализа. В совокупности это определяет функциональные и архитектурные требования, реализованные в проекте.

3 РАЗРАБОТКА

3.1 Используемые технологии

В процессе разработки клиентской части приложения использовался набор библиотек и инструментов, обеспечивающих построение интерфейса, обработку данных и контроль качества кода. Основой проекта является фреймворк Next.js, применяемый для организации структуры интерфейса и работы рендеринга на базе React и ReactDOM, где React отвечает за компонентную модель, а ReactDOM обеспечивает отображение компонентов в браузере. Типизация проекта выполнена с использованием TypeScript, позволяющего выполнять статический анализ и предотвращать ошибки на этапе разработки, а проверка качества кода обеспечивается инструментом ESLint, который контролирует стиль и выявляет некорректные конструкции. Для проверки клиентских данных используется библиотека Valibot, предоставляющая декларативные схемы валидации, тогда как для отображения сообщений с разметкой задействуется react-markdown. Адаптивность интерфейса поддерживается через react-responsive, а набор универсальных хуков react-use применяется для решения прикладных задач, связанных с обработкой состояний, событий и браузерных API. Библиотека the-new-css-reset используется для унификации базовых стилей, обеспечивая предсказуемое визуальное поведение интерфейса, а подключение типографики реализовано через @fontsource-variable/nunito-sans, предоставляющий вариативный формат шрифта с оптимизированной загрузкой.

3.2 Демонстрация пользовательского интерфейса

На всех экранах приложения присутствует фиксированная верхняя шапка (header), содержащая три управляющих элемента (рисунок 3.1).

Слева направо: иконка «гамбургер-меню» — открывает боковую панель со списком чатов (недоступна до аутентификации); иконка силуэта пользователя — вызывает модальное окно входа/регистрации; иконка переключателя темы — изменяет оформление приложения циклично (светлая → тёмная → сепия). иконка динамически меняется в зависимости от текущей темы: луна для светлой, лист для тёмной и солнце для сепии.

Рисунок *3.1* – Постоянная верхняя шапка приложения

Рисунок 3.2 демонстрирует стартовую страницу для неавторизован-

ного пользователя в мобильной версии. Экран содержит только верхнюю шапку и одну крупную центральную кнопку «Зарегистрироваться», дублирующую действие иконки профиля. После успешной аутентификации кнопка исчезает, оставляя экран на пустом первом чате.

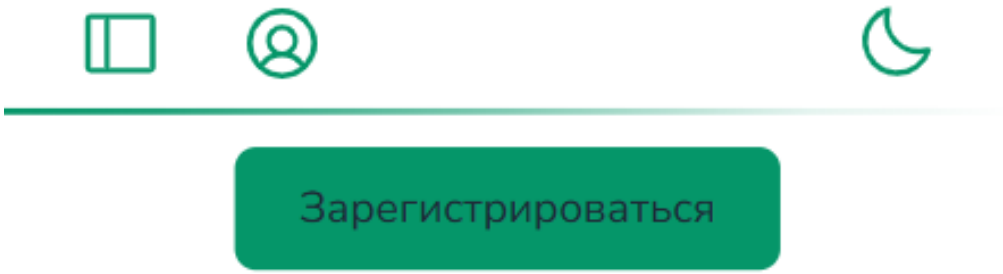

Рисунок *3.2* – Стартовая страница — мобильная версия (неавторизованный пользователь)

Рисунок 3.3 показывает ту же стартовую страницу в десктопной версии. Поведение и состав элементов полностью идентичны мобильной версии.

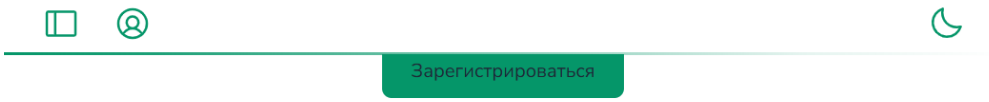

Рисунок *3.3* – Стартовая страница — десктопная версия (неавторизованный пользователь)

Рисунок 3.4 отображает интерфейс регистрации нового пользователя. Окно выдвигается с правой стороны экрана, перекрывая и затемняя основное содержимое. Форма содержит три поля ввода: логин, email и пароль. Основная кнопка подписана как «Зарегистрироваться» и инициирует

создание новой учётной записи. В нижней части формы расположен блок навигации с гиперссылкой «Войти в аккаунт», обеспечивающей переход к форме аутентификации.

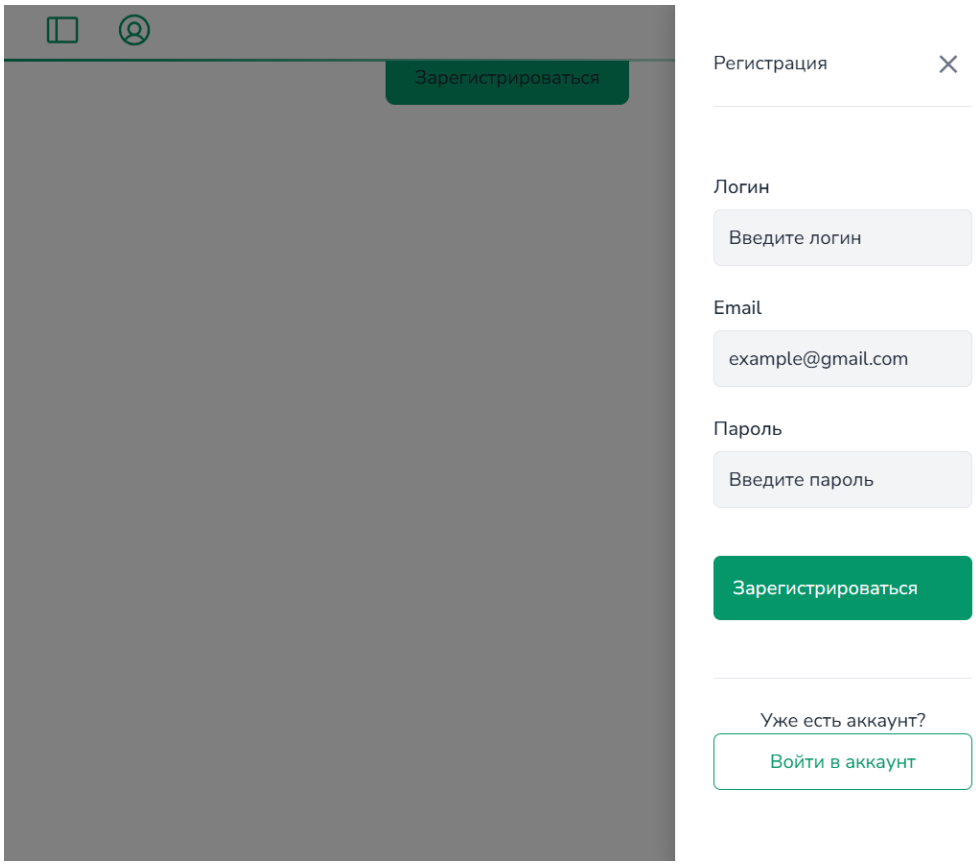

Рисунок *3.4* – Модальное окно регистрации пользователя

Рисунок 3.5 показывает тот же интерфейс регистрации в мобильной версии. Поведение и состав элементов полностью идентичны десктопной версии, единственная разница заключается в том что окно перекрывает весь размер страницы.

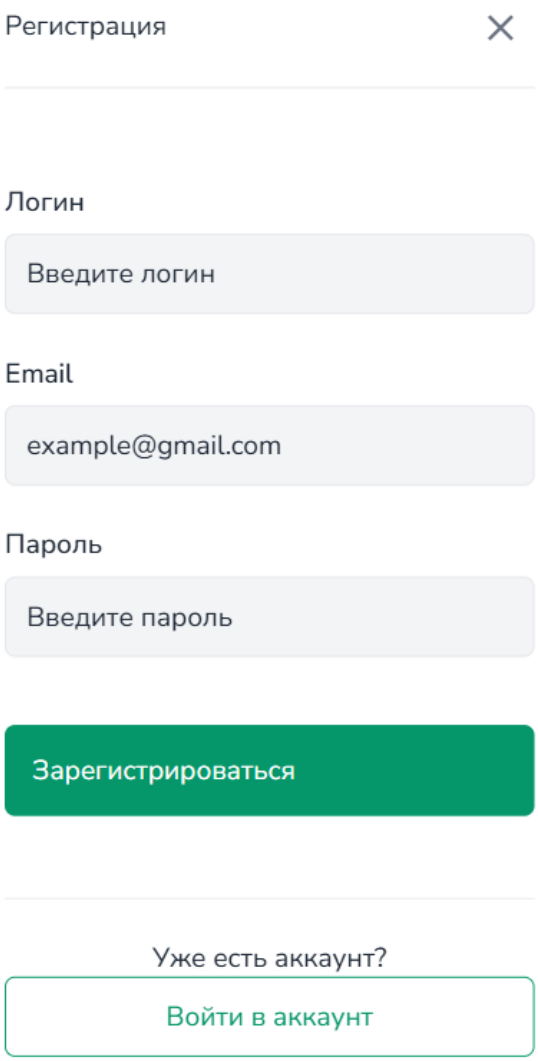

Рисунок *3.5* – Модальное окно регистрации пользователя(мобильная версия)

Рисунок 3.6 иллюстрирует модальное окно аутентификации. Его структура идентична форме регистрации, за исключением отсутствия поля email. Отображаются только поля для логина и пароля, а основная кнопка имеет подпись «Войти» и инициирует загрузку данных пользователя. Нижний навигационный блок содержит ссылку «Зарегистрироваться», возвращающую пользователя к форме регистрации. Окно также выдвигается справа и закрывается по клику на иконку крестика в правом верхнем углу или вне его области.

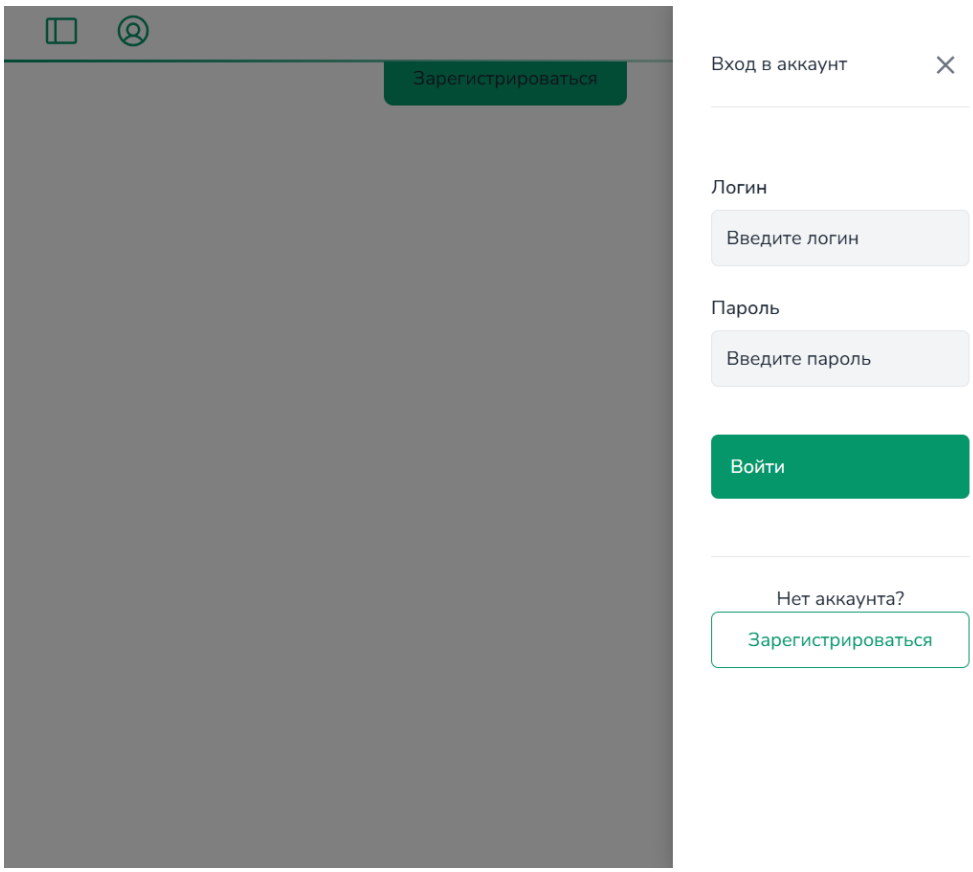

Рисунок *3.6* – Модальное окно входа в систему

Рисунок 3.7 показывает тот же интерфейс аутентификации в мобильной версии. Поведение и состав элементов полностью идентичны десктопной версии, единственная разница заключается в том что окно перекрывает весь размер страницы.

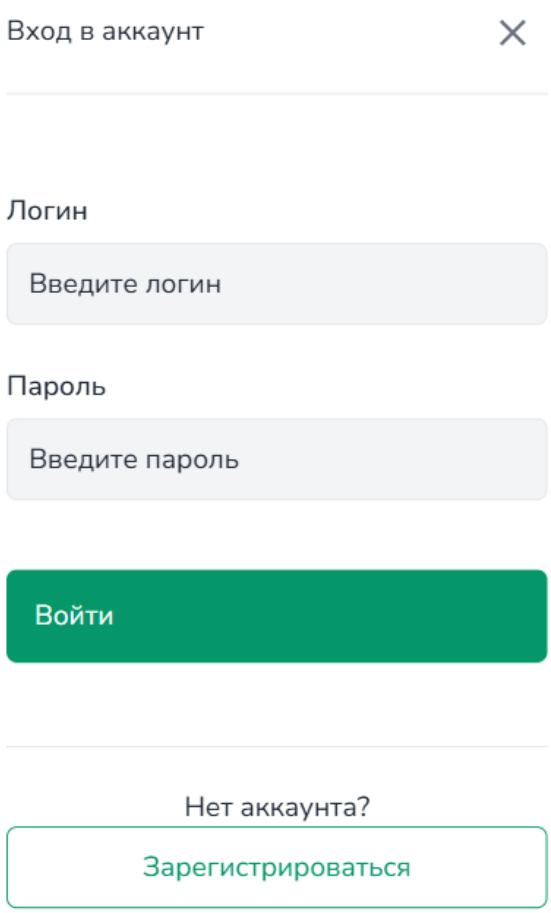

Рисунок *3.7* – Модальное окно входа в систему(мобильная версия)

Рисунок 3.8 демонстрирует состояние боковой навигационной панели «Мои чаты», обеспечивающей доступ к списку диалогов пользователя. Активный в данный момент чат визуально выделяется цветовым фоном и индикатором в виде галочки. В верхней части списка расположен интерактивный элемент «Создать новый чат» для инициализации новой сессии, а также крестик для закрытия панели.

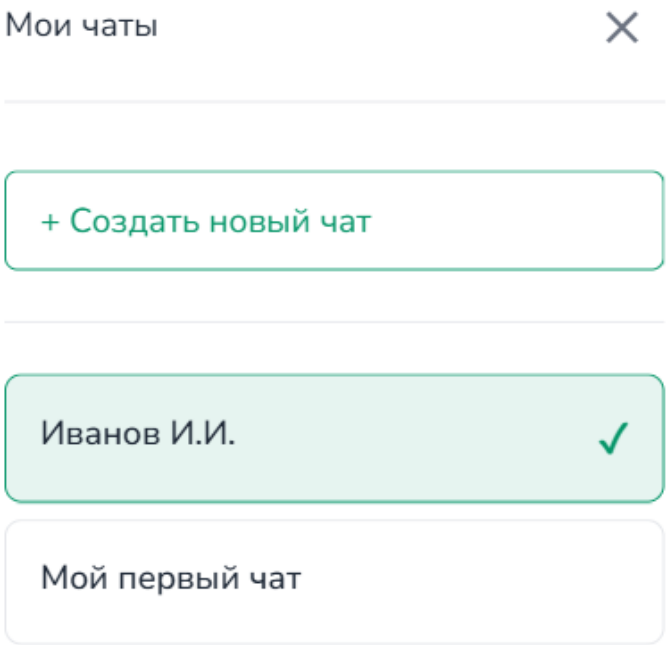

Рисунок *3.8* – Боковая панель со списком активных диалогов

При инициализации создания нового диалога интерфейс панели трансформируется в форму, представленную на рисунке 3.9. Пользователю предлагается поле для ввода названия чата с текстовой подсказкой о поведении системы по умолчанию: в случае отсутствия ввода чату будет автоматически присвоено имя «Новый чат». Блок управления содержит кнопки подтверждения операции и отмены, возвращающей пользователя к списку диалогов.

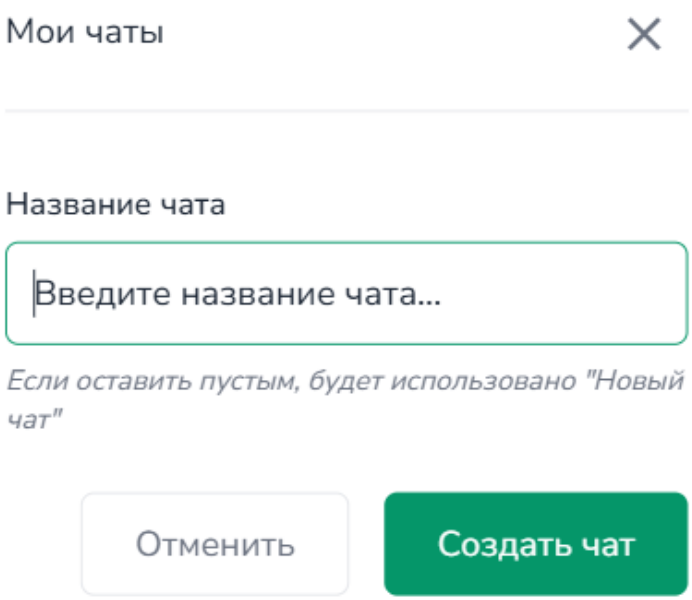

Рисунок *3.9* – Интерфейс создания нового чата

Рисунок 3.10 отображает функциональную область ввода сообщений, расположенную в нижней части экрана диалога. Данный блок содержит поле для ввода текста с подсказкой, кнопки для прикрепления фотографии и создания фотографии, расположенные слева, а также кнопку отправки сообщения справа. Кнопка отправки визуально выделена цветом если есть текст или фотография и приглушена если отсутствуют обе.

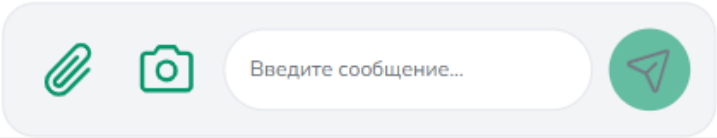

Рисунок *3.10* – Панель ввода и отправки сообщений

Рисунок 3.11 демонстрирует компонент сообщения, содержащего вложенный контент (изображение) от пользователя. При нажатии на изображение оно пропадает. Одновременно можно загрузить только 1 изображение.

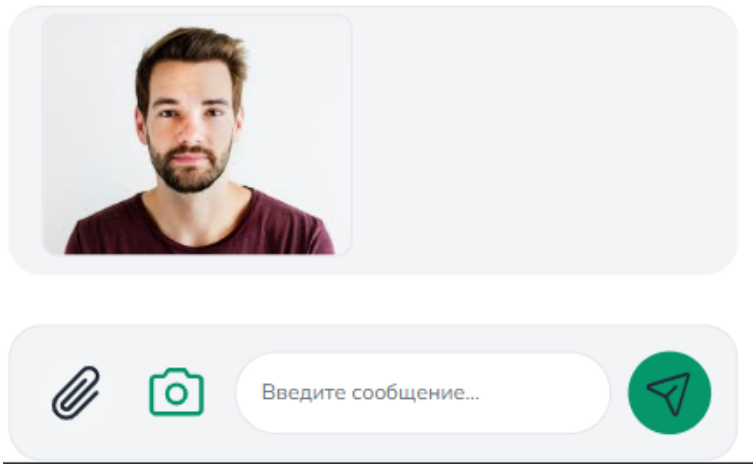

Рисунок *3.11* – Визуализация загруженного сообщения в интерфейсе чата

Рисунок 3.12 демонстрирует базовую структуру отображения текстового диалога, где исходящие сообщения (от пользователя) выравниваются по правому краю и выделены контрастным цветовым фоном, а входящие сообщения (от собеседника или подсистемы, как показано на рисунке) выравниваются по левому краю, имеют нейтральное оформление и могут сопровождаться аватаром отправителя.

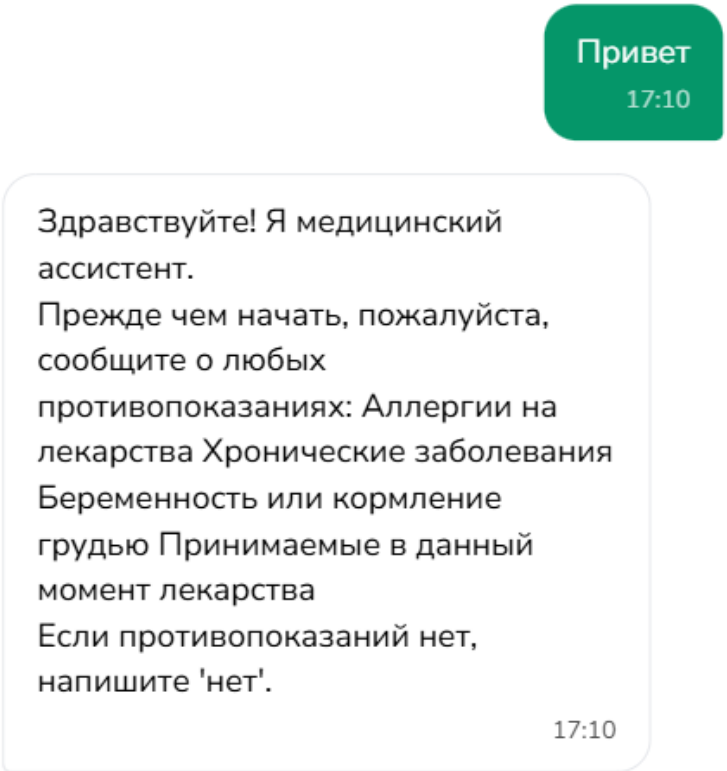

Рисунок *3.12* – Структура отображения текстовых сообщений

Рисунок 3.13 иллюстрирует компонент сообщения, содержащего вложенный контент, отправленный пользователем (изображение). В данном случае, сообщение, являющееся исходящим, выравнивается по правому краю и включает отображение загруженного медиафайла. В ответ на это сообщение может следовать форматированный ответ от подсистемы анализа, который также отображается в виде входящего блока.

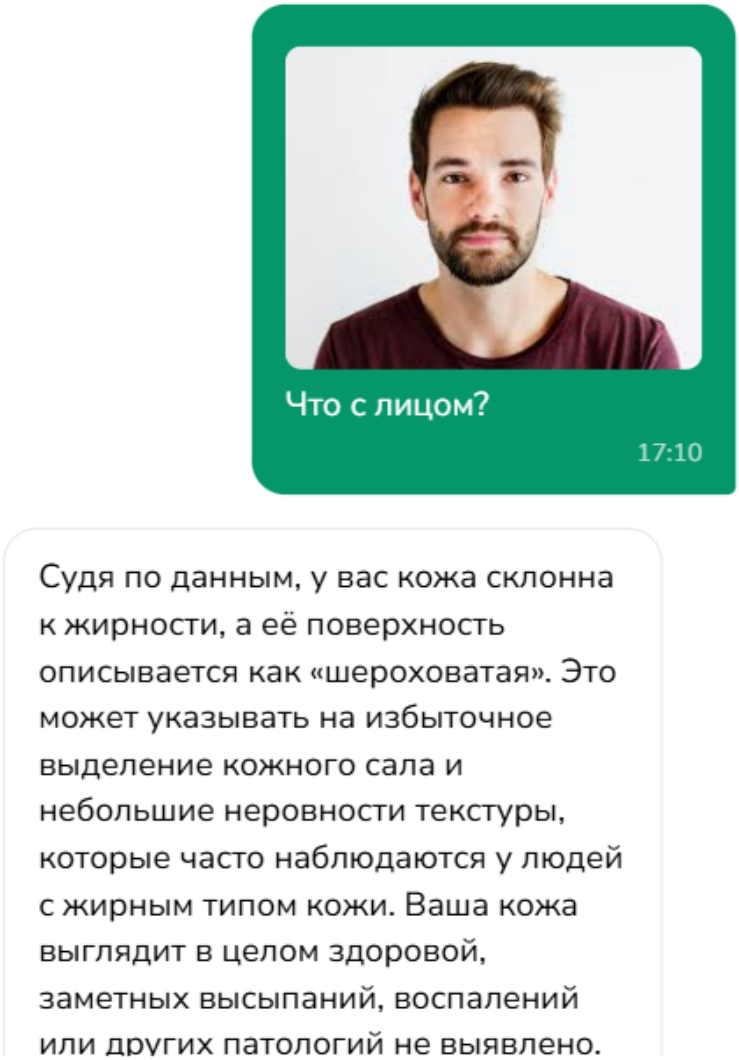

Рисунок *3.13* – Сообщение от подсистемы анализа лица

3.3 Тестирование

Тестирование клиентской части включало проверку корректности работы интерфейса, маршрутов обработки сообщений и механизма аутентификации. Для контроля качества кода применялся линтер ESLint, который позволил выявить и устранить ошибки, связанные с нарушениями синтаксических правил, некорректными конструкциями и типичными проблемами при использовании React и TypeScript. В рамках функционального тестиро-

вания были проверены сценарии сохранения пользовательского состояния: после обновления страницы или повторного входа данные аутентификации корректно считываются из локального хранилища и обеспечивают восстановление рабочей сессии. Проверены оба маршрута обработки сообщений: при отправке изображения запрос передаётся в подсистему анализа лица, а при вводе текстовых данных — в модуль формирования фармакотерапии. Дополнительно протестированы механизмы переключения тем, управление списком чатов, корректность отображения адаптивного интерфейса и обработка единичного прикрепления изображения, что подтвердило стабильность работы основных пользовательских сценариев.

3.4 Вывод

В ходе разработки системы формирования медицинских рекомендаций была реализована архитектура, обеспечивающая автоматизированную обработку пользовательских запросов с разделением логики по типу входных данных. Интеграция локальной языковой модели, задействованной для формирования фармакотерапии, и многоагентной подсистемы анализа лица позволяет обрабатывать как текстовые запросы, так и изображения без участия пользователя в выборе режима работы. Построенный механизм уточнения симптоматики и проверки противопоказаний обеспечивает детализированную генерацию терапевтических рекомендаций, а многоагентная схема анализа изображений гарантирует последовательную интерпретацию визуальных признаков и структурированное формирование итогового текста.

Клиентская часть, разработанная на Next.js с использованием TypeScript и набора специализированных библиотек, реализует функциональный чат-интерфейс с поддержкой аутентификации, управления списком диалогов и адаптивного отображения. Механизмы хранения данных на стороне клиента и сервера обеспечивают восстановление контекста при повторных обращениях, а применение валидации и статического анализа кода повышает устойчивость интерфейса к ошибкам. Проведённое тестирование подтвердило корректность маршрутов обработки данных, стабильность поведения интерфейса и согласованную работу с подсистемами сервера.

Реализованная архитектура создаёт основу для дальнейшего расширения функциональности. Возможны интеграция дополнительных диагностических модулей, улучшение алгоритмов интерпретации изображений, расширение логики диалога в текстовом режиме и масштабирование клиентской части. Текущая структурная организация компонентов обеспечивает возможность развития системы без необходимости существенного изменения её базовых механизмов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] OpenAI. GPT-4o System Card. — 2024. — Официальная документация OpenAI. https://openai.com/index/gpt-4o-system-card/.

[2] Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning / H.-C. Shin, H. R. Roth, M. Gao [et al.] // IEEE Transactions on Medical Imaging. — 2016. — Vol. 35, no. 5. — Pp. 1285–1298. https://ieeexplore.ieee.org/document/7393806.

[3] Retrieval-Augmented Generation for Large Language Models: A Survey / M. Hershman, P. Banerjee, S. Hausler [et al.] // arXiv. — 2023. — Обзор современных RAG-систем. https://arxiv.org/abs/2309.15023.

[4] Dermatologist-level classification of skin cancer with deep neural networks / A. Esteva [et al.] // Nature. — 2017. — Vol. 542. — Pp. 115–118. https://www.nature.com/articles/nature21056.

[5] Deep learning for healthcare: review, opportunities and challenges / R. Miotto [et al.] // Briefings in Bioinformatics. — 2017. — Vol. 19. — Pp. 1236–1246. https://academic.oup.com/bib/article/19/6/1236/2562806.

[6] Baur, C. Deep Autoencoding Models for Unsupervised Anomaly Segmentation in Medical Images / C. Baur, S. Albarqouni, N. Navab // Medical Image Analysis. — 2022. — Vol. 73. — 102–141 P. https://www.sciencedirect.com/science/article/pii/S1361841521003224.

[7] A convolutional neural network for automatic classification of skin lesions as benign or malignant / T. J. Brinker, A. Hekler, A. H. Enk [et al.] // European Journal of Cancer. — 2019. — Vol. 119. — Pp. 121–129. https://www.sciencedirect.com/science/article/pii/S0959804919305064.

[8] Organization, World Health. Skin Conditions: Global Health Estimates. — 2024. — Официальный ресурс ВОЗ. https://www.who.int/health-topics/dermatology.

[9] Food, U.S. FDA Drug Database and Labeling Information. — 2024. — Официальная база лекарственных средств FDA. https://www.fda.gov/drugs/drug-databases.

[10] Zealand, DermNet New. DermNet: Dermatology Information Resource. — 2025. — Медицинская база знаний по дерматологии. https://dermnetnz.org/.

[11] Ronneberger, O. U-Net: Convolutional Networks for Biomedical Image Segmentation / O. Ronneberger, P. Fischer, T. Brox // Medical Image

Computing and Computer-Assisted Intervention (MICCAI). — 2015. — Pp. 234–241. https://arxiv.org/abs/1505.04597.