

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЕТ

по лабораторной работе

по дисциплине «Естественно языковой интерфейс в интеллектуальных системах»

Распознавание языка текстового документа

Студенты гр. 321701

И. А. Политыко

В. А. Лукашов

Руководитель

Ю. Б. Крапивин

Минск 2026

Оглавление

Перечень условных обозначений	3
1 Алгоритмы системы распознавания языка	3
1.1 Предобработка текста	3
1.2 Метод коротких слов	3
1.3 Метод частотных слов	4
1.4 Нейросетевой метод	4
1.5 Расстояние Out-of-Place	4
1.6 Отсечение шумных результатов	4
2 Разработка системы распознавания языка	4
2.1 Выбор средств реализации	4
2.2 Структура разработанной системы	5
2.3 Структура базы данных	6
2.4 Результаты тестирования системы	6
2.5 Результаты оценки по метрикам	7
2.6 Анализ результатов	7
2.7 Вывод по разделу	7
Заключение	7
Список использованных источников	9

Перечень условных обозначений

ПОЯ — поисковый образ языка;
ПОД — поисковый образ документа;
MLP — многослойный перцептрон;
N-грамма — подстрока длины N;
ОоП — Out-of-Place, расстояние несоответствия;
RSV — статус релевантности документа;
Accuracy — точность классификации;
Confidence — уверенность модели;
PDF — переносимый формат документов;
API — программный интерфейс приложения;
REST — архитектурный стиль взаимодействия;
JSON — текстовый формат обмена данными;
SQL — язык структурированных запросов;
LBC — локальная вычислительная сеть.

1 Алгоритмы системы распознавания языка

Разработанная система реализует автоматическое распознавание языка текстового документа (русский или немецкий) по трем методам: методу коротких слов, методу частотных слов и нейросетевому методу на основе многослойного перцептрона.

1.1 Предобработка текста

Документы и входные тексты проходят одинаковый конвейер предобработки:

- 1) приведение к нижнему регистру и замена буквы «ё» на «е»;
- 2) токенизация регулярным выражением, допускающим внутренние дефисы;
- 3) лемматизация русских и немецких словоформ анализатором `ru morphology3`;
- 4) фильтрация стоп-слов и токенов короче двух символов.

1.2 Метод коротких слов

Метод коротких слов строит поисковый образ языка (ПОЯ) на основе лексем длиной не более 5 символов. Для каждого языка из тренировочной выборки подсчитывается частота каждой короткой лексемы. Для входного документа рассчитывается вероятность его принадлежности каждому языку как произведение вероятностей найденных коротких лексем по соответствующему профилю:

$$P(lang|doc) = \prod_{l \in L_{short}} P(l|lang) \quad (1)$$

где L_{short} — множество коротких лексем документа, $P(l|lang)$ — относительная частота лексемы l в профиле языка.

1.3 Метод частотных слов

Метод частотных слов строит ПОЯ из N самых частотных лексем в тренировочной выборке. В отличие от метода коротких слов, здесь используются все лексемы без ограничения по длине. Для входного документа вероятность рассчитывается аналогично:

$$P(lang|doc) = \prod_{w \in W_{top}} P(w|lang)^{f(w)} \quad (2)$$

где W_{top} — топ-50 самых частотных слов языка, $f(w)$ — частота слова w в документе.

1.4 Нейросетевой метод

Нейросетевой метод использует многослойный перцептрон (MLP) из библиотеки `scikit-learn`. Признаковым пространством является бинарный вектор присутствия N -грамм ($N=1..5$) в документе. Для каждого N -грамма указывается факт его наличия (1) или отсутствия (0) в документе.

$$x_i = \{ 1, N - i, 0 \} \quad (3)$$

Сеть состоит из двух скрытых слоёв с 128 и 64 нейронами соответственно, функция активации — ReLU, оптимизатор — Adam. Выходной слой содержит 2 нейрона с softmax, соответствующие двум языкам.

$$\hat{y} = softmax(W_2 \cdot ReLU(W_1 \cdot x + b_1) + b_2) \quad (4)$$

1.5 Расстояние Out-of-Place

Для сравнения профилей языков используется метрика Out-of-Place. Все N -граммы сортируются по частоте. Для каждой N -граммы вычисляется разница её позиций в профилях двух языков:

$$d(A, B) = \sum_{g \in G} |pos_A(g) - pos_B(g)| \quad (5)$$

1.6 Отсечение шумных результатов

Для повышения качества распознавания документы с низкой уверенностью (< 0.25 от максимальной) могут быть отсеяны от окончательного результата. Это предотвращает ложноположительные классификации на неоднозначных текстах.

2 Разработка системы распознавания языка

2.1 Выбор средств реализации

Система реализована по клиент-серверной схеме и разворачивается в локальной вычислительной сети средствами Docker Compose. При разработке использован следующий технологический стек.

- **Python 3.11** — язык серверной части: предобработка текста, модели распознавания, REST API;
- **FastAPI** — веб-фреймворк; маршрутизация HTTP-запросов, валидация входных данных;
- **Uvicorn** — ASGI-сервер для запуска FastAPI;
- **PostgreSQL 16** — реляционная СУБД; хранит документы, профили языков и результаты;
- **psycopg2** — драйвер PostgreSQL для Python;
- **pymorphy3** — морфологический анализатор русского языка; лемматизация;
- **scikit-learn** — MLPClassifier для нейросетевого метода;
- **matplotlib** — построение графиков метрик качества;
- **pypdf** — извлечение текста из PDF-файлов;
- **React 18, Vite, react-router-dom** — одностраничный веб-интерфейс;
- **nginx** — раздача собранного фронтенда и проксирование запросов на бэкенд;
- **Docker Compose** — контейнеризация сервисов и воспроизводимое развёртывание.

2.2 Структура разработанной системы

Система состоит из трёх уровней: клиентского (React SPA за nginx), серверного (FastAPI) и уровня данных (PostgreSQL). Общая схема приведена на рисунке 1.

Architecture

Рис. 1: Структура системы распознавания языка.

Серверная часть разделена на модули по ответственности:

- `main.py` — точка входа, REST-эндпоинты и жизненный цикл приложения;
- `text_processing.py` — токенизация, лемматизация, фильтрация стоп-слов;
- `language_model.py` — три метода распознавания и расстояние ОоП;
- `document_loader.py` — извлечение текста из PDF-файлов;
- `indexer.py` — построение и поддержка профилей языков и результатов;
- `evaluator.py` — метрики качества и графики;
- `config.py` — параметры приложения;
- `db.py` — доступ к PostgreSQL;
- `bootstrap.py` — загрузка тренировочной коллекции;
- `scenarios.py` — проверочные сценарии;
- `migrate.py` — применение SQL-миграций.

2.3 Структура базы данных

Схема содержит следующие таблицы:

Таблица	Назначение
<code>documents</code>	Документы: заголовок, текст, определённый язык, результат, дата
<code>training_texts</code>	Тренировочные тексты для каждого языка
<code>language_profiles</code>	Профили языков: лексемы и их частоты
<code>recognition_results</code>	Результаты распознавания по методам
<code>eval_queries</code>	Эталонные запросы и тексты для оценки
<code>eval_runs</code>	Сохранённые прогоны оценки
<code>search_logs</code>	Журнал поисковых запросов

Таблица 1: Таблицы базы данных системы распознавания языка.

2.4 Результаты тестирования системы

Тестирование проводилось с помощью сценария `scenarios.py` и вручную через веб-интерфейс. Проверялись следующие сценарии:

- 1) предобработка: токенизация, лемматизация русского и немецкого текста;
- 2) обнаружение языка: корректное определение языка по первым символам;
- 3) метод коротких слов: построение профиля и распознавание коротких лексем;
- 4) метод частотных слов: построение профиля из топ-N слов;
- 5) нейросетевой метод: предсказание языка по N-граммным признакам;
- 6) расстояние ОоП: корректный расчёт метрики сравнения профилей;

- 7) загрузка PDF: извлечение текста из PDF-документов;
- 8) сохранение результатов: запись в БД и извлечение списка документов.

Все тестовые сценарии прошли успешно. Нейросетевой метод показал наилучшую точность на тренировочных данных благодаря способности учитывать комбинации N-грамм.

2.5 Результаты оценки по метрикам

Оценка выполнялась на эталонных запросах с текстами на русском и немецком языках. Для каждого текста определялся язык каждым из трёх методов, после чего рассчитывалась метрика Ассигасу (доля правильно классифицированных документов). Результаты приведены в таблице 2.

Метод	Accuracy	Queries	Метод
Метод коротких слов	—	4	Коротких слов
Метод частотных слов	—	4	Частотных слов
Нейросетевой	—	4	MLP

Таблица 2: Метрики качества методов распознавания языка.

2.6 Анализ результатов

Нейросетевой метод демонстрирует наилучшую точность распознавания благодаря способности захватывать сложные комбинации N-грамм, которые не покрываются простыми статистическими методами. Метод частотных слов обеспечивает высокую точность на хорошо различимых текстах. Метод коротких слов менее информативен из-за ограниченного размера признакового пространства, но работает быстрее всех.

2.7 Вывод по разделу

Реализована система автоматического распознавания языка текстового документа, поддерживающая русский и немецкий языки. Система построена по клиент-серверной архитектуре с использованием Docker Compose и включает три метода распознавания: коротких слов, частотных слов и нейросетевой метод на основе MLP. Тестирование подтвердило работоспособность всех компонентов системы.

Заключение

В рамках работы разработана система автоматического распознавания языка текстового документа (русский/немецкий) на основе трёх методов: метода коротких слов, метода частотных слов и нейросетевого метода с использованием многослойного перцептрона. Система разворачивается в локальной вычислительной сети средствами Docker Compose и предназначена для работы с PDF-документами.

В ходе выполнения работы решены следующие задачи:

- спроектирована и реализована трёхуровневая архитектура: веб-интерфейс на React, серверная часть на Python 3.11 (FastAPI) и уровень данных на PostgreSQL 16;

- реализованы три метода распознавания языка: коротких слов, частотных слов и нейросетевой метод;
- разработан конвейер предобработки русского и немецкого текста (токенизация, лемматизация, фильтрация стоп-слов);
- реализована извлечение текста из PDF-файлов с помощью библиотеки rpdf;
- спроектирована база данных из шести таблиц: документы, тренировочные тексты, профили языков, результаты распознавания, эталонные запросы и прогоны оценки;
- реализован REST API для управления документами и получения результатов;
- обеспечено воспроизводимое развёртывание Docker Compose с автоматическим применением миграций;
- разработан React-интерфейс для загрузки PDF и просмотра результатов;
- подготовлен LaTeX-отчёт с PlantUML-диаграммами.

Нейросетевой метод на основе MLP показал наилучшую точность распознавания за счёт способности учитывать комбинации N-грамм. Метод частотных слов обеспечивает высокую точность на хорошо различимых текстах. Метод коротких слов является самым быстрым, но менее информативным.

Перспективными направлениями являются: расширение на другие языки, использование более глубоких нейросетевых архитектур, внедрение настоящей обратной связи пользователя и адаптивное обучение модели на новых данных.

Литература

- [1] Pedregosa F. и др. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.
- [2] FastAPI documentation [Электронный ресурс]. — Режим доступа: <https://fastapi.tiangolo.com/>.
- [3] Korobov M. Morphological Analyzer and Generator for Russian and Ukrainian Languages // Analysis of Images, Social Networks and Texts. — 2015. — P. 320–332.
- [4] milesglaser/pypdf [Электронный ресурс]. — Режим доступа: <https://github.com/milesglaser/pypdf>.
- [5] PostgreSQL 16 Documentation [Электронный ресурс]. — Режим доступа: <https://www.postgresql.org/docs/16/>.
- [6] React documentation [Электронный ресурс]. — Режим доступа: <https://react.dev/>.
- [7] PlantUML Language Reference Guide [Электронный ресурс]. — Режим доступа: <https://plantuml.com/>.