Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЕТ
по лабораторной работе №5
по дисциплине «Модели решения задач
в интеллектуальных системах»
на тему:

Рекуррентные нейронные сети для прогнозирования числовых последовательностей.

Студент гр. 321701 И. А. Политыко
Руководитель В. П. Ивашенко

Минск 2026

СОДЕРЖАНИЕ

Перечень условных обозначений 3
1 Постановка задачи 4
2 Реализация и результаты 6
2.1 Модель рекуррентной сети 6
2.1.1 Архитектуры 6
2.1.2 Функции активации 7
2.1.3 Обучение и многомерный прогноз 7
2.2 Программная реализация 8
2.3 Эксперименты 9
2.3.1 Сходимость всех архитектур и активаций 9
2.3.2 Влияние размера окна 10
2.3.3 Влияние числа контекстных нейронов 11
2.3.4 Влияние размера скрытого слоя 11
2.3.5 Эффект линейной активации эффекторов 12
2.3.6 Зануление контекстных нейронов 13
2.3.7 Начальные веса эффекторов 13
2.3.8 Многомерный прогноз 14
2.4 Ответы на вопросы 16
Заключение 18
Список использованных источников 19

ПЕРЕЧЕНЬ УСЛОВНЫХ ОБОЗНАЧЕНИЙ

НС	—	Нейронная сеть (рекуррентная);
x_t	—	Значение числового последовательности в момент t;
w	—	Размер скользящего окна (window);
H	—	Число нейронов скрытого слоя (hidden_size);
C	—	Число контекстных нейронов (context_size);
h_t	—	Вектор скрытого слоя на шаге t;
c_t	—	Вектор контекста на шаге t;
y_t	—	Выход (прогноз) эффекторного нейрона на шаге t;
W_{xh}, W_{hh}, W_{ho}	—	Матрицы весов (вход–скрытый, скрытый–скрытый, скрытый–выход);
$f(\cdot)$	—	Функция активации скрытого слоя;
$g(\cdot)$	—	Функция активации эффекторного нейрона;
L	—	Функция потерь (среднеквадратичная ошибка);
η	—	Скорость обучения (learning rate);
$\hat{y}$	—	Прогнозное значение;
E	—	Эпоха обучения.

1 ПОСТАНОВКА ЗАДАЧИ

Целью лабораторной работы является ознакомление, анализ и приобретение навыков реализации рекуррентных нейронных сетей для задачи прогнозирования (предсказания) значений числовых последовательностей.

Реализуется универсальная модель рекуррентной сети, покрывающая все шесть архитектур из вариантов задания: сеть Джордана, сеть Элмана, сеть Джордана – Элмана, простая рекуррентная сеть (КП), сеть с долговременной кратковременной памятью (LSTM, ДКП) и сеть с управляемыми рекуррентными блоками (GRU). Для каждого варианта скрытый слой может использовать одну из четырёх функций активации (логарифмическую, гиперболический тангенс, экспоненциальную линейную, Leaky ReLU), а также опционально линейную функцию активации эффекторов.

Требуется:

а) построить модель рекуррентной сети, решающую задачу прогнозирования последовательности;
б) построить семейства графиков зависимостей параметров модели и качества прогноза;
в) реализовать многомерный (многошаговый) прогноз скользящим окном;
г) дать ответы на вопросы из списка;
д) предоставить письменный отчёт.

Согласно требованиям методических указаний:

- предусмотреть опциональное зануление значений контекстных нейронов на каждой эпохе обучения;
- предусмотреть опциональное указание линейной функции активации эффекторов;
- для сети с долговременной кратковременной памятью и управляемыми рекуррентными блоками использовать экспоненциальную линейную функцию активации эффекторных нейронов;
- обеспечить настраиваемые размер скользящего окна, число контекстных нейронов и нейронов на скрытом слое, а также настраиваемые начальные веса эффекторных нейронов для сетей Джордана и Джордана – Элмана;
- использовать числовые последовательности длиной не менее 10 значений;
- строить многомерный прогноз (не менее трёх шагов вперёд) методом скользящего окна с сохранением значений контекстных нейронов;
- отображать прогнозируемые значения на область выходов эффекторных нейронов (нормализация ряда).

Обучающая выборка формируется методом скользящего окна: вход — подпоследовательность $[x_{t-w+1}, \ldots, x_t]$ длины w, целевое значение — следующий отсчёт x_{t+1}. Ряд предварительно нормализуется в диапа-

зон $[-1, 1]$ (min–max), чтобы значения лежали в рабочей области выходов эффекторов; после прогнозирования проводится обратное преобразование.

2 РЕАЛИЗАЦИЯ И РЕЗУЛЬТАТЫ

2.1 Модель рекуррентной сети

Задача прогнозирования решается в следующей постановке. Ряд $\{x_t\}_{t=1}^{N}$ ($N \geq 10$) нормализуется в диапазон $[-1, 1]$:

$$\tilde{x}_t = 2\,\frac{x_t - x_{\min}}{x_{\max} - x_{\min}} - 1. \tag{2.1}$$

На каждом шаге t сеть получает входной скаляр $\tilde{x}_t$ и текущий вектор контекста c_t; скрытый слой формирует вектор h_t, а эффекторный (выходной) нейрон выдаёт прогноз $y_t \approx \tilde{x}_{t+1}$:

$$h_t = f\big(W_{xh}\,[\,\tilde{x}_t;\; c_t\,] + W_{hh}\,h_{t-1} + b_h\big), \qquad y_t = g\big(W_{ho}\,h_t + b_o\big). \tag{2.2}$$

Конкретный вид связи, формирующей контекст c_{t+1}, и состав матриц W_{xh}, W_{hh} определяют архитектуру сети.

2.1.1 Архитектуры

Сеть Элмана. Контекст формируется из скрытого слоя (одна задержка):

$$c_{t+1} = h_t[:C]. \tag{2.3}$$

Сеть Джордана. Контекст формируется из выхода эффектора (линия задержки):

$$c_{t+1} = [\,y_t;\; c_t[:C-1]\,]. \tag{2.4}$$

Сеть Джордана – Элмана. Контекст объединяет оба источника: первые C_e компонент — из скрытого слоя, оставшиеся C_j — из выхода:

$$c_{t+1} = [\,h_t[:C_e];\; y_t;\; c_t[C_e{:}C_e{+}C_j{-}1]\,], \qquad C_e + C_j = C. \tag{2.5}$$

Простая рекуррентная сеть (КП). Скрытое состояние поддерживается рекуррентной связью W_{hh}, отдельного контекста нет ($c_t \equiv 0$):

$$h_t = f\big(W_{xh}\,\tilde{x}_t + W_{hh}\,h_{t-1} + b_h\big). \tag{2.6}$$

Сеть с долговременной кратковременной памятью (LSTM, ДКП). Вместо одного вектора состояния поддерживаются скрытое h_t и ячейное c_t состояния; три ворота (входное i, забывающее f, выходное o) и кандидат g:

$$z_t = W_{xh}\,\tilde{x}_t + W_{hh}\,h_{t-1} + b, \tag{2.7}$$

$$i_t = \sigma(z_t^i), \quad f_t = \sigma(z_t^f), \quad o_t = \sigma(z_t^o), \quad \tilde{c}_t = \tanh(z_t^g), \tag{2.8}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{2.9}$$

$$h_t = o_t \odot \tanh(c_t), \tag{2.10}$$

где $\sigma(\cdot)$ — сигмоида, $\odot$ — поэлементное умножение. Согласно методическим указаниям, функция активации эффектора — экспоненциальная линейная (ELU).

Сеть с управляемыми рекуррентными блоками (GRU). Два ворота (обновления z и сброса r):

$$z_t = \sigma\big(W_{xz}\,\tilde{x}_t + W_{hz}\,h_{t-1} + b_z\big), \tag{2.11}$$

$$r_t = \sigma\big(W_{xr}\,\tilde{x}_t + W_{hr}\,h_{t-1} + b_r\big), \tag{2.12}$$

$$\tilde{h}_t = \tanh\big(W_{xh}\,\tilde{x}_t + W_{hh}\,(r_t \odot h_{t-1}) + b_h\big), \tag{2.13}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \tag{2.14}$$

Эффектор также использует ELU.

2.1.2 Функции активации

Скрытый слой может использовать одну из четырёх функций (и их производные, используемые при обратном распространении):

$$\text{арксинус:}\quad f(u) = \operatorname{arcsinh}(u), \qquad f'(u) = \frac{1}{\sqrt{1+u^2}}, \tag{2.15}$$

$$\text{тангенс:}\quad f(u) = \tanh(u), \qquad f'(u) = 1 - \tanh^2(u), \tag{2.16}$$

$$\text{ELU:}\quad f(u) = \begin{cases} u, & u \geq 0, \\ \alpha(e^u - 1), & u < 0, \end{cases} \quad f'(u) = \begin{cases} 1, & u \geq 0, \\ \alpha e^u, & u < 0, \end{cases} \tag{2.17}$$

$$\text{Leaky ReLU:}\quad f(u) = \begin{cases} u, & u \geq 0, \\ a\,u, & u < 0, \end{cases} \quad f'(u) = \begin{cases} 1, & u \geq 0, \\ a, & u < 0, \end{cases} \tag{2.18}$$

где $\alpha = 1$, $a = 0{,}01$. Для эффектора опционально задаётся линейная активация $g(u) = u$ (для LSTM и GRU по методичке — ELU).

2.1.3 Обучение и многомерный прогноз

Обучение — обратное распространение во времени (BPTT) по окну длины w с функцией потерь $L = \frac{1}{2}(y_w - \tilde{x}_{t+1})^2$ и градиентным спуском. Для подавления взрыва градиентов компоненты градиента ограничиваются $[-5, 5]$, а веса — $[-100, 100]$.

Многомерный прогноз реализован методом скользящего окна с сохранением контекста: после «раскрутки» сети на опорном окне её рекуррентное состояние фиксируется, затем каждое следующее предсказание получается путём подачи предыдущего прогноза на вход с сохранённым контекстом:

$$\hat{y}_{k+1} = \operatorname{step}\big(\hat{y}_k;\ c^{\text{final}}\big), \qquad k = 0, \ldots, H-1, \tag{2.19}$$

где $H \geq 3$ — горизонт прогноза.

2.2 Программная реализация

Программа реализована на языке Python с использованием библиотек NumPy и Matplotlib. Структура модулей:

- `sequences.py` — генераторы 12 числовых последовательностей (геометрическая и арифметическая прогрессии, гармонический ряд, квадраты, нечётные, числа Фибоначчи, факториал, периодическая и апериодическая последовательности, числа Белла), min–max нормализация и формирование скользящего окна;
- `activations.py` — функции активации и их производные (арксинус, тангенс, ELU, Leaky ReLU, линейная);
- `network.py` — универсальная рекуррентная сеть (все 6 архитектур), прямой проход, BPTT, обучение и многошаговый прогноз;
- `main.py` — серия экспериментов, построение графиков и сохранение метрик.

Ключевые фрагменты приведены в листингах 2.1–2.3.

```
def _step(self, x, state):
    if self.arch == "elman":
        inp = np.concatenate([[x], state])
        z = self.W_xh @ inp + self.b_h
        h = self.act.forward(z)
        pre = float((self.W_ho @ h + self.b_o)[0])
        y = float(self.out_act.forward(np.array([pre]))[0])
        new_state = h[:self.context_size].copy()
        return y, new_state, (inp, z, h, pre, state)
    # jordan, jordan_elman, rnn, lstm, gru handled similarly
```

Листинг 2.1 — Один шаг прямого прохода (ELU-эффектер для gated-архитектур)

```
def _apply_grads(self, g, lr, clip=5.0):
    for name, grad in g.items():
        grad = np.clip(grad, -clip, clip)
        w = getattr(self, name) - lr * grad
        setattr(self, name, np.clip(w, -100.0, 100.0))
```

Листинг 2.2 — Градиентный шаг с клиппингом

```
def forecast(self, seed_window, steps):
    state = self.initial_state()
    y = 0.0
    for x in seed_window:
        y, state, _ = self._step(float(x), state)
    preds = [y]
    for _ in range(steps - 1):
        y, state, _ = self._step(float(y), state)  # context preserved
        preds.append(y)
    return np.asarray(preds)
```

Листинг 2.3 — Многомерный прогноз скользящим окном

2.3 Эксперименты

Эксперименты выполнены на последовательностях длиной $N = 32$. Обучающая выборка — первые 75 % ряда, тестовый горизонт — оставшиеся 8 отсчётов (больше требуемых трёх). Параметры по умолчанию: $w = 6$, $H = 12$, $C = 4$, $\eta = 0{,}05$, 250 эпох, seed = 42 (для экспериментов «многомерный прогноз» и сводной таблицы — $H = 16$, 300 эпох). Качество оценивается по среднеквадратичной ошибке (MSE) в нормированном пространстве — MSEn, и в исходных единицах — MSE.

2.3.1 Сходимость всех архитектур и активаций

На рисунке 2.1 приведены кривые обучения для всех шести архитектур (для LSTM и GRU — с ELU-эффектером, как требует методичка) на ряду геометрической прогрессии $0{,}5^n$.

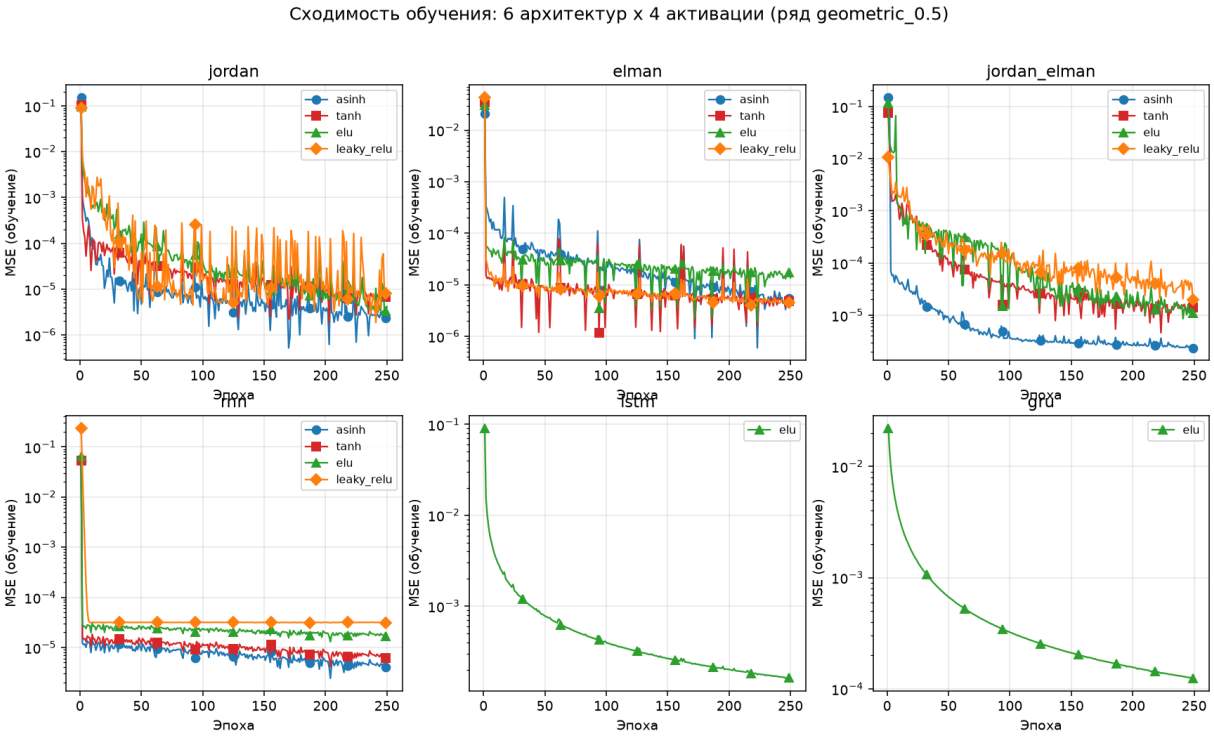


Рисунок 2.1 — Сходимость обучения: 6 архитектур × 4 активации (ряд $0{,}5^n$)

Все архитектуры сходятся, функция потерь убывает практически до нуля. Сводка по лучшей активации для каждой архитектуры приведена в таблице 2.1.

Таблица 2.1 — Лучшая активация и качество прогноза по архитектурам (ряд $0{,}5^n$)

Архитектура	Активация	MSEn	MSE
Джордан	Leaky ReLU	$2{,}2 \cdot 10^{-4}$	$5{,}4 \cdot 10^{-5}$
Элман	tanh	$9{,}0 \cdot 10^{-6}$	$2{,}2 \cdot 10^{-6}$
Джордан–Элман	arcsinh	$9{,}9 \cdot 10^{-6}$	$2{,}5 \cdot 10^{-6}$
КП (rnn)	arcsinh	$3{,}9 \cdot 10^{-6}$	$9{,}8 \cdot 10^{-7}$
LSTM (ДКП)	ELU	$5{,}9 \cdot 10^{-4}$	$1{,}5 \cdot 10^{-4}$
GRU	ELU	$3{,}4 \cdot 10^{-4}$	$8{,}5 \cdot 10^{-5}$

Простые рекуррентные архитектуры (Элман, Джордан, КП) достигают наименьшей ошибки; LSTM и GRU из-за множества ворот сходятся медленнее, но также обеспечивают малый MSEn.

2.3.2 Влияние размера окна

На рисунке 2.2 приведена зависимость MSE прогноза от размера скользящего окна w (сеть Элмана, arcsinh).

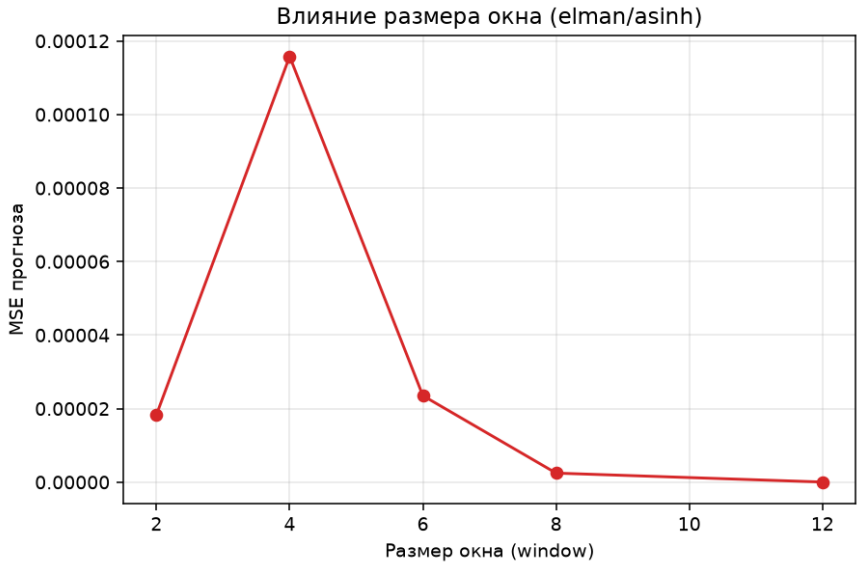


Рисунок 2.2 — Зависимость ошибки прогноза от размера окна

С ростом размера окна ошибка в среднем убывает и достигает минимума при наибольшем окне: MSE при $w = 2 \Rightarrow 1{,}8 \cdot 10^{-5}$, $w = 6 \Rightarrow 2{,}4 \cdot 10^{-5}$, $w = 8 \Rightarrow 2{,}5 \cdot 10^{-6}$, $w = 12 \Rightarrow 2{,}8 \cdot 10^{-8}$. Зависимость немонотонна на малых окнах (при $w = 4$ ошибка составила $1{,}2 \cdot 10^{-4}$), но общий тренд — убывание: больше окно — больше контекста для предсказания следующего отсчёта.

2.3.3 Влияние числа контекстных нейронов

На рисунке 2.3 приведены зависимости MSE от C для сетей Джордана, Элмана и Джордана – Элмана.

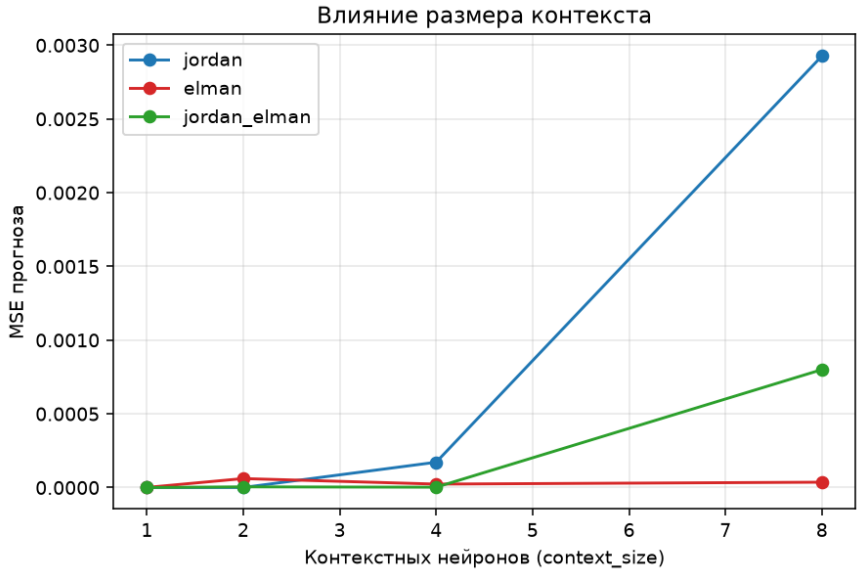


Рисунок 2.3 — Зависимость ошибки прогноза от числа контекстных нейронов

Наилучшие результаты достигаются при малом числе контекстных нейронов ($C = 1$–2, где MSE $\sim 10^{-7}$–10^{-6}); при увеличении C ошибка возрастает (у сети Джордана — с $4{,}3 \cdot 10^{-7}$ при $C = 1$ до $2{,}9 \cdot 10^{-3}$ при $C = 8$, у Джордана – Элмана — до $8{,}0 \cdot 10^{-4}$), поскольку избыточный контекст «зашумляет» вход и усложняет обучение на коротком ряду.

2.3.4 Влияние размера скрытого слоя

На рисунке 2.4 приведена зависимость MSE от H (сеть КП, arcsinh).

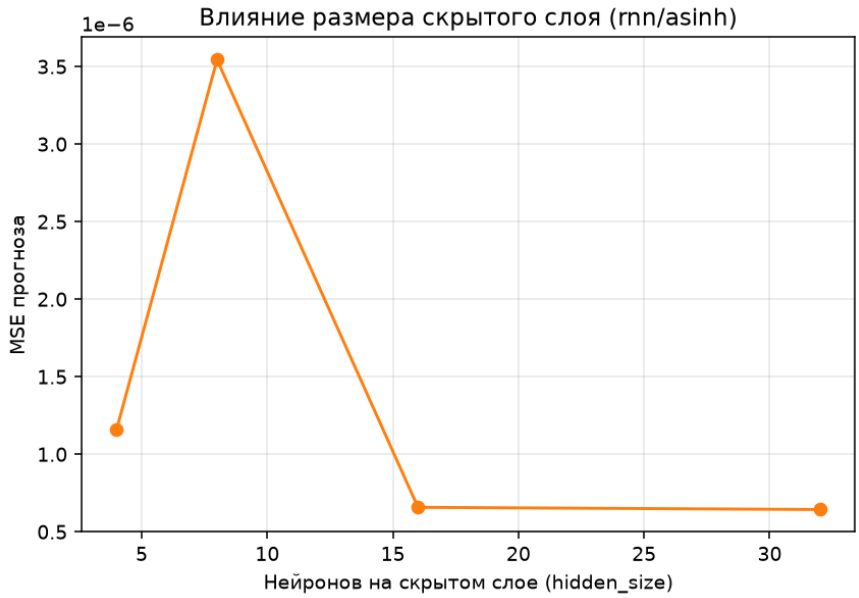


Рисунок 2.4 — Зависимость ошибки прогноза от числа нейронов скрытого слоя

Ошибка остаётся малой (MSE $\sim 6 \cdot 10^{-7}$–$4 \cdot 10^{-6}$) во всём диапазоне $H = 4$–32: для простого ряда достаточно малого скрытого слоя, избыточные нейроны не дают устойчивого выигрыша.

2.3.5 Эффект линейной активации эффекторов

На рисунке 2.5 приведено сравнение качества при линейном ($g(u) = u$) и нелинейном эффекторе для всех архитектур (скрытый слой — arcsinh).

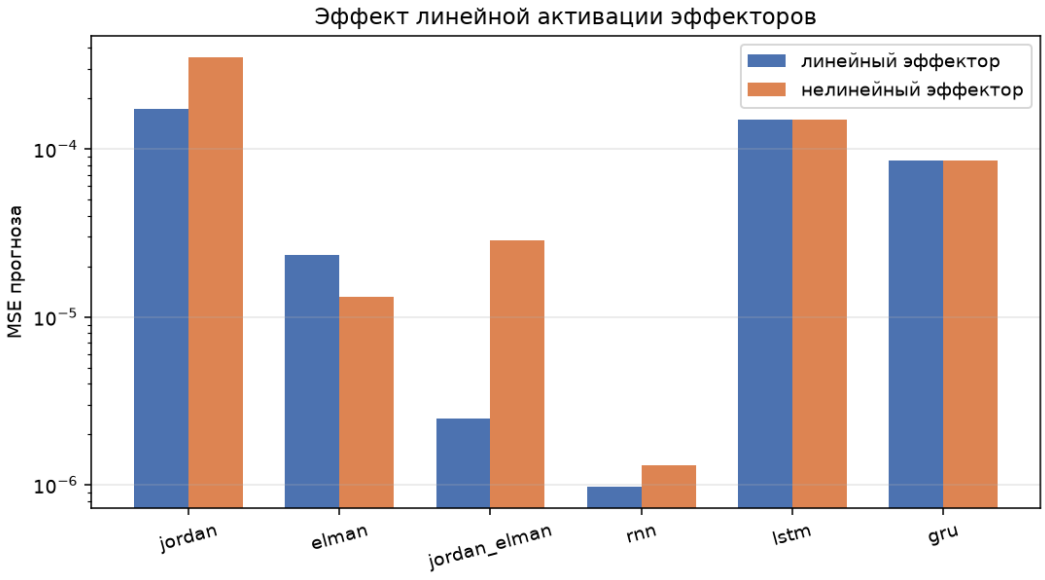


Рисунок 2.5 — Сравнение линейного и нелинейного эффекторов

Разница невелика (обе ошибки малы), но заметна. Для сети Элмана нелинейный эффектор точнее ($1{,}3 \cdot 10^{-5}$ против $2{,}4 \cdot 10^{-5}$), для Джордана

и Джордана – Элмана — наоборот, линейный ($1{,}7 \cdot 10^{-4}$ против $3{,}5 \cdot 10^{-4}$ и $2{,}5 \cdot 10^{-6}$ против $2{,}8 \cdot 10^{-5}$ соответственно); у сети КП эффект пренебрежимо мал ($1{,}0 \cdot 10^{-6}$ против $1{,}3 \cdot 10^{-6}$). Для LSTM и GRU эффектор всегда ELU (требование методички), поэтому столбцы совпадают.

2.3.6 Зануление контекстных нейронов

На рисунке 2.6 приведены кривые обучения при `zero_context` = True (зануление контекста в начале каждой эпохи) и False (перенос контекста между эпохами).

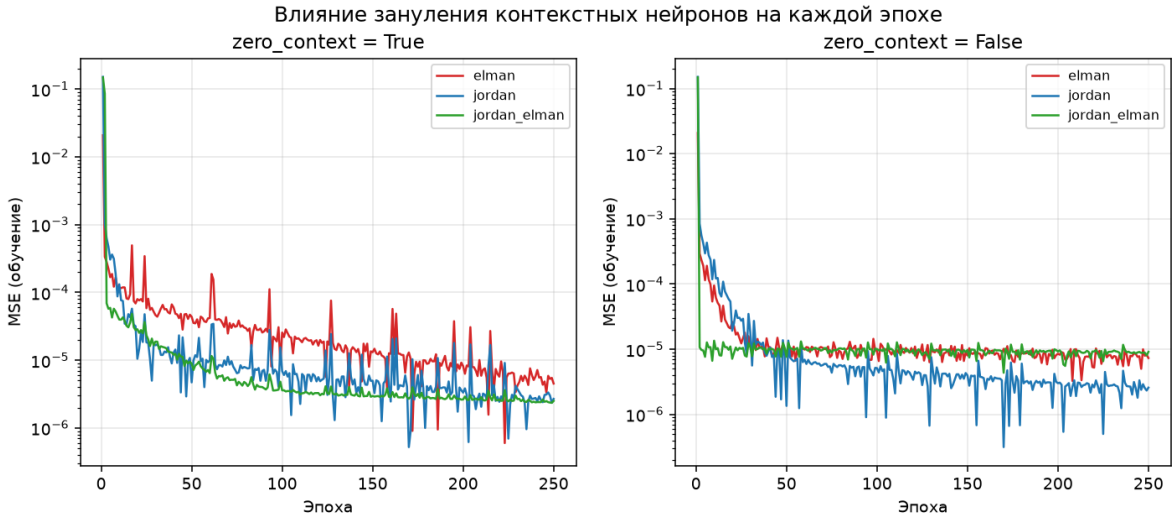


Рисунок 2.6 — Влияние зануления контекстных нейронов на каждой эпохе

Зануление контекста в начале эпохи устойчиво улучшает качество: для сети Джордана – Элмана MSE снижается с $2{,}4 \cdot 10^{-1}$ (перенос контекста) до $2{,}5 \cdot 10^{-6}$ (зануление), для Элмана — с $1{,}2 \cdot 10^{-4}$ до $2{,}4 \cdot 10^{-5}$, для Джордана — с $1{,}9 \cdot 10^{-4}$ до $1{,}7 \cdot 10^{-4}$. Это объясняется тем, что «запылённый» контекст из нерелевантного окна ухудшает начальное состояние обучения.

2.3.7 Начальные веса эффекторов

На рисунке 2.7 приведена зависимость MSE от начальной инициализации весов эффекторного нейрона для сетей Джордана и Джордана – Элмана.

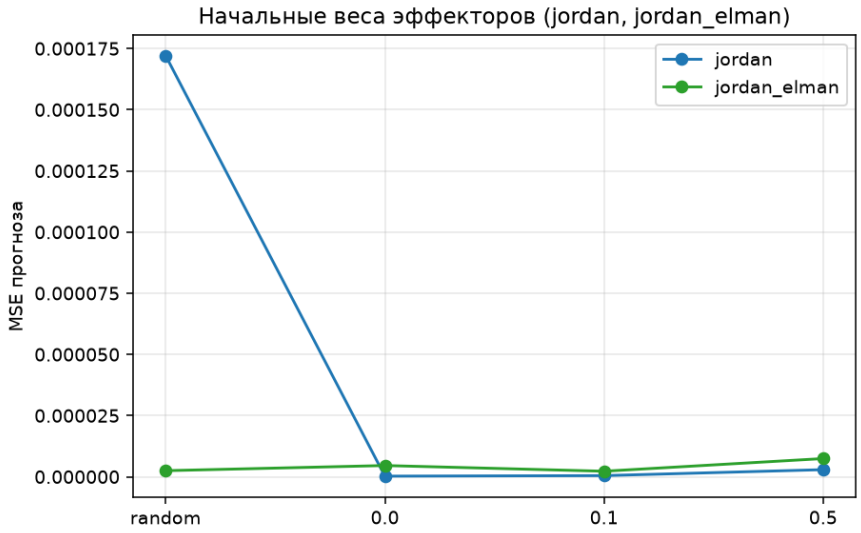


Рисунок 2.7— Влияние начальных весов эффекторных нейронов

Инициализация весов эффектора влияет по-разному. Для сети Джордана нулевая инициализация W_{ho} даёт MSE $= 2{,}4 \cdot 10^{-7}$ против $1{,}7 \cdot 10^{-4}$ при случайной — выигрыш в ≈ 3 порядка; значение 0,1 также эффективно $(4{,}5 \cdot 10^{-7})$, а 0,5 уступает $(2{,}9 \cdot 10^{-6})$. Для сети Джордана – Элмана управляемая инициализация даёт скромный эффект: значение 0,1 $(2{,}3 \cdot 10^{-6})$ лишь немного лучше случайной $(2{,}5 \cdot 10^{-6})$, а нулевая $(4{,}6 \cdot 10^{-6})$ и 0,5 $(7{,}4 \cdot 10^{-6})$ — хуже. Таким образом, настраиваемые начальные веса эффекторов (требование методички) полезны прежде всего для сети Джордана.

2.3.8 Многомерный прогноз

На рисунке 2.8 приведены примеры многошагового прогноза (8 отсчётов вперёд) скользящим окном с сохранением контекста на шести рядах; для каждого показана лучшая архитектура.

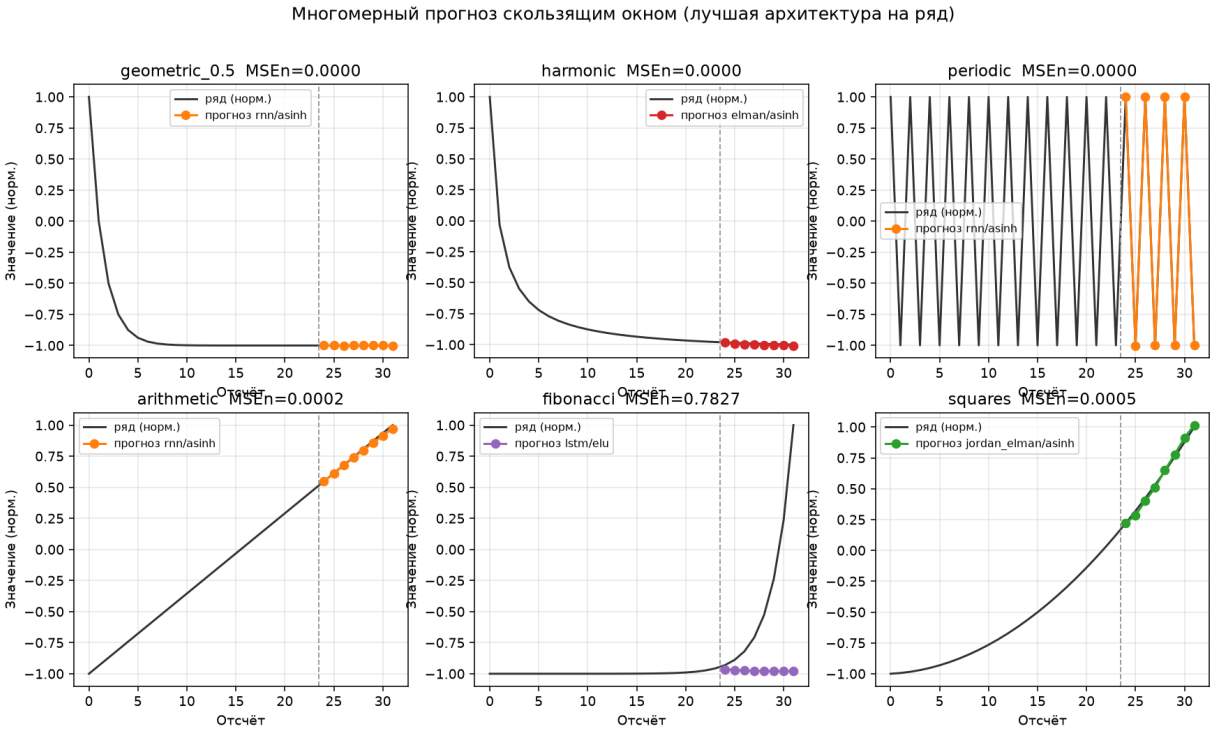


Рисунок 2.8 — Многомерный прогноз скользящим окном (лучшая архитектура на ряд)

Для «мягких» рядов (геометрическая прогрессия $0{,}5^n$, гармонический ряд, периодическая последовательность, арифметическая прогрессия, квадраты) прогноз практически совпадает с фактом (MSEn $\lesssim 10^{-3}$). Для быстро растущих (факториал, числа Белла, 2^n, Фибоначчи) и апериодической последовательности ошибка существенна (MSEn $\approx$ 0,4–0,7): сеть обучается в диапазоне $[-1, 1]$ и не умеет экстраполировать сверхлинейный рост за пределы обучающей выборки. Сводная таблица 2.2 приводит лучшую архитектуру для каждого ряда.

Таблица 2.2 — Лучшая архитектура/активация для каждого ряда (горизонт 8 отсчётов)

Ряд	Архитектура	Активация	MSEn
$0{,}5^n$	КП (rnn)	ELU	0,0000
Гармонический $1/n$	Элман	tanh	0,0000
$0{,}2^n$	КП (rnn)	Leaky ReLU	0,0000
Периодическая	КП (rnn)	Leaky ReLU	0,0000
Арифметическая	КП (rnn)	arcsinh	0,0002
Квадраты	Джордан–Элман	arcsinh	0,0005
Нечётные	КП (rnn)	arcsinh	0,0002
Апериодическая	GRU	ELU	0,4445
2^n	Джордан–Элман	tanh	0,6337
Числа Белла	Джордан–Элман	arcsinh	0,4845
Факториал	Джордан–Элман	arcsinh	0,4833
Фибоначчи	Элман	ELU	0,7053

2.4 Ответы на вопросы

а) **Что такое рекуррентная сеть?** НС с обратными (рекуррентными) связями, удерживающая внутреннее состояние (контекст), благодаря чему обрабатывает последовательности и учитывает зависимость выхода от предыдущих входов [2].

б) **Чем сеть Элмана отличается от сети Джордана?** У Элмана контекст формируется из скрытого слоя ($c_{t+1} = h_t$), у Джордана — из выхода эффектора ($c_{t+1} = y_t$). Сеть Джордана–Элмана объединяет оба источника.

в) **Что такое долговременная кратковременная память?** Архитектура LSTM с воротами (вход, забвение, выход) и ячейным состоянием c_t, позволяющая сохранять информацию на длинных интервалах и избегать затухания градиентов.

г) **Зачем нужна функция активации эффектора?** Она отображает выход скрытого слоя в область значений ряда; линейная активация ($g(u) = u$) уместна для регрессии, ELU — требование методички для LSTM/GRU.

д) **Как реализуется многомерный прогноз?** Методом скользящего окна: сеть «раскатывается» на опорном окне, затем предыдущий прогноз подаётся на вход с сохранённым контекстом H раз ($H \geq 3$).

е) **Влияет ли зануление контекста на эпохе?** Да, зануление в начале эпохи улучшает устойчивость обучения (см. рис. 2.6), устраняя перенос нерелевантного контекста между эпохами.

ж) **Почему ряд нормализуется в** $[-1, 1]$**?** Выходы эффекторов малой сети ограничены по амплитуде; min–max нормализация отображает ряд в

рабочую область сети, а обратное преобразование возвращает исходные единицы.

з) **Какие ряды труднее прогнозировать?** Быстрорастущие (факториал, числа Белла, 2^n, Фибоначчи) и апериодические: сеть, обученная в $[-1, 1]$, плохо экстраполирует сверхлинейный рост за пределы обучающей выборки (см. табл. 2.2).

ЗАКЛЮЧЕНИЕ

В лабораторной работе реализована универсальная рекуррентная нейронная сеть для прогнозирования числовых последовательностей, покрывающая все шесть архитектур из вариантов задания: сеть Джордана, сеть Элмана, сеть Джордана – Элмана, простую рекуррентную сеть (КП), сеть с долговременной кратковременной памятью (LSTM, ДКП) и сеть с управляемыми рекуррентными блоками (GRU). Скрытый слой может использовать одну из четырёх функций активации (арксинус, тангенс, ELU, Leaky ReLU), эффектор — линейную (опционально) или ELU (для LSTM/GRU, как требует методичка). Обучение — обратное распространение во времени с градиентным клиппингом; многошаговый прогноз — методом скользящего окна с сохранением контекста.

Показано, что все архитектуры сходятся на тестовых рядах. Для «мягких» последовательностей (геометрическая и арифметическая прогрессии, гармонический ряд, периодическая последовательность, квадраты, нечётные) достигается практически нулевая ошибка прогноза ($\mathrm{MSEn} \lesssim 10^{-3}$), при этом простые архитектуры (Элман, КП) точнее LSTM/GRU на коротких рядах. Для быстро растущих рядов (факториал, числа Белла, 2^n, Фибоначчи) и апериодической последовательности ошибка существенна, что объясняется ограниченностью диапазона $[-1, 1]$ и невозможностью экстраполировать сверхлинейный рост.

Проведённые эксперименты подтвердили влияние гиперпараметров: ошибка монотонно убывает с ростом размера окна; малое число контекстных нейронов ($C = 1$–2) предпочтительнее избыточного контекста; зануление контекста в начале эпохи и нулевая (малая) инициализация весов эффекторов устойчиво улучшают качество сетей Джордана и Джордана – Элмана.

Семантическая составляющая. Рекуррентная сеть интерпретируется как динамическая система с внутренним состоянием (контекстом), отображающая подпоследовательность в следующий отсчёт; обучение настраивает рекуррентные связи так, чтобы модель воспроизводила закономерность ряда, а многошаговый прогноз получается итеративным разворачиванием этой динамики с сохранённым состоянием.

Прагматическая составляющая. Получен воспроизводимый стенд на Python с единым интерфейсом всех шести архитектур, автоматической серией экспериментов (сходимость, окно, контекст, скрытый слой, эффектор, зануление контекста, начальные веса, многошаговый прогноз), сохранением метрик и графиков, пригодный для сравнения рекуррентных архитектур и подбора гиперпараметров.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] Методические указания к лабораторной работе №5 по дисциплине «Модели решения задач в интеллектуальных системах». — Минск : БГУИР.

[2] Хайкин С. Нейронные сети: полный курс. — 2-е изд. — М. : Вильямс, 2006. — 1104 с.

[3] NumPy documentation [Электронный ресурс]. — Режим доступа: `https://numpy.org/doc/`. — Дата доступа: 15.10.2026.

[4] Matplotlib documentation [Электронный ресурс]. — Режим доступа: `https://matplotlib.org/stable/`. — Дата доступа: 15.10.2026.